



Sorbonne Université

Faculté des Lettres

**ÉVALUATION DES SYSTÈMES DE
RECONNAISSANCE VOCALE
À L'AIDE DES MÉTRIQUES
ISSUES DE LA TRADUCTION AUTOMATIQUE**

Mémoire de Master 1

Frédéric Rosenthal et Marc Cocaïgn

Directeur de mémoire : Claude Montacié

2024 – 2025

**Évaluation des systèmes de reconnaissance vocale
à l'aide de métriques issues de la traduction automatique**

Mémoire de Master 1

Spécialité : Sciences du Langage, Parcours Langue et Informatique

Domaine : Traitement Automatique des Langues

Frédéric Rosenthal

16006276

Marc Cocaign

21101218

Directeur de mémoire : Claude Montacié

Année académique : 2024 - 2025

Soutenance prévue en septembre 2025,
à la Maison de la Recherche,
28 rue Serpente 75006 Paris

Faculté des Lettres - Sorbonne Université

REMERCIEMENTS

Nous tenons à exprimer notre profonde gratitude à notre directeur de mémoire, Monsieur Montacié, pour avoir suggéré ce sujet et guidé notre travail grâce à ses précieux conseils. Nous remercions plus largement l'équipe pédagogique du Master, d'avoir instauré un climat d'apprentissage favorable à l'accomplissement de ce travail exigeant. Enfin, nous sommes très reconnaissants envers nos professeurs de nous avoir transmis, au cours de cette première année de Master, des connaissances riches et variées dans le domaine du traitement automatique du langage.

RÉSUMÉ

Ce travail de recherche et d'expérimentations est une réponse à la multiplication des systèmes de génération de transcriptions d'audio et d'outils pour évaluer leurs productions. L'objectif principal est de comparer des systèmes d'ASR variés et étudier le fonctionnement de diverses métriques. Nous utilisons pour cela les enregistrements vocaux libres de droits provenant de LibriSpeech et SupremeCourt, des corpus largement reconnus dans le domaine de la reconnaissance de la parole. Ces ressources nous permettent de dresser un *benchmark* des systèmes à travers différents niveaux d'analyse. Nous démontrons que, parmi un choix de cinq modèles de reconnaissance de la parole reconnus, le plus performant est Canary-1B-Flash. Ce même outil a très récemment été publié sous la version Canary-1b-v2, plus lourde mais plus performante. Nous explorons également les comportements de nos quelques métriques utilisées, en comparant des approches provenant du domaine de la traduction automatique telles que BLEU avec les méthodes classiques de taux d'erreurs.

TABLE DES MATIÈRES

Remerciements.....	3
Résumé.....	4
Table des matières.....	5
Liste des abréviations.....	7
Liste des tableaux.....	8
1. Introduction.....	9
1.1 Contexte et problématique.....	9
1.2 Outils utilisés.....	10
1.3 Objectifs.....	12
2. Cadre théorique.....	13
2.1 Enjeux de la reconnaissance automatique de la parole.....	13
2.2 Présentation des modèles d'ASR.....	14
2.2.1 DeepSpeech.....	14
2.2.2 Wav2Vec2.....	15
2.2.3 Whisper.....	16
2.2.4 SeamlessM4T.....	17
2.2.5 Canary.....	18
2.3 Présentation des métriques.....	19
2.3.3 WER.....	19
2.3.4 Semantic-WER.....	20
2.3.1 BLEU.....	21
2.3.2 METEOR.....	22
2.3.5 BERTSCORE.....	22
3. État de l'art.....	24
3.1 Usages et travaux récents.....	24
3.2 Affirmations des auteurs des modèles et résultats obtenus.....	27
3.2.1 DeepSpeech.....	27
3.2.2 Wav2Vec2.....	28
3.2.3 Whisper.....	28
3.2.4 SeamlessM4T.....	29
3.2.5 Canary.....	30
3.3 Autres outils performants.....	31
4. Méthodologie.....	33
4.1 Sélection des ressources.....	33
4.1.1 Description du corpus LibriSpeech.....	33
4.1.2 Description du corpus Oyez de la Cour Suprême.....	34
4.1.3 Choix des modèles.....	35
4.1.4 Choix des métriques.....	36
4.2 Prétraitement et alignement des données.....	37
4.3 Conception et mise en œuvre du pipeline.....	39
4.4 Protocole d'évaluation et axes d'analyse.....	40
5. Résultats et discussion.....	42
5.1 Résultats des expériences.....	42
5.1.1 Résultats par modèle.....	42

5.1.2 Résultats selon le corpus.....	44
5.1.3 Résultats selon la taille des segments.....	46
5.2 Discussion.....	47
5.2.1 Interprétation des résultats des systèmes d'ASR.....	48
5.2.2 Analyses des scores au niveau du segment.....	48
6. Conclusion.....	51
6.1 Synthèse des résultats.....	51
6.2 Limites de l'étude.....	52
6.3 Perspectives.....	54
Bibliographie.....	56

LISTE DES ABRÉVIATIONS

TAL / NLP : Traitement Automatique du Langage / *Natural Language Processing*

TTS : *Text-to-Speech* (Synthèse vocale)

STT : *Speech-to-Text* (Reconnaissance vocale)

ASR : *Automatic Speech Recognition* (Reconnaissance automatique de la parole)

WER : *Word Error Rate* (Taux d'erreur en mots)

SWER : *Substitute Word Error Rate* (Taux d'erreur de mots substitués)

BLEU : *Bilingual Evaluation Understudy* (Métrique d'évaluation de traduction)

GPU : *Graphics Processing Unit* (Processeur graphique)

WAV : *Waveform Audio File Format* (Format de fichier audio)

LLMs : *Large Language Models* (Grands modèles de langage)

RNN : *Recurrent Neural Network* (Réseau de neurones récurrent)

LSTM : *Long Short-Term Memory* (Mémoire à long terme)

CTC : *Connectionist Temporal Classification* (Classification temporelle)

PER : *Phoneme Error Rate* (Taux d'erreur phonémique)

BPE : *Byte Pair Encoding* (Encodage par paires d'octets)

X2T : *X to Text* (Entrée de langue quelconque vers texte)

T2TT : *Text to Text Translation* (Traduction texte à texte)

S2TT : *Speech to Text Translation* (Traduction parole à texte)

T2ST : *Text to Speech Translation* (Traduction texte à parole)

S2ST : *Speech to Speech Translation* (Traduction parole à parole)

IDF : *Inverse Document Frequency* (Fréquence inverse de document)

CNN : *Convolutional Neural Network* (Réseau de neurones convolutif)

SRU : *Simple Recurrent Unit* (Unité récurrente simple)

MFA : *Montreal Forced Aligner* (Outil d'alignement phonétique)

JSON : *JavaScript Object Notation* (Format de données JSON)

HMM-DNN : *Hidden Markov Model - Deep Neural Network* (Modèle de Markov caché - réseau de neurones profond)

MSR-86K : *Microsoft Research 86K* (Corpus ou base de données)

NER : *Named Entity Recognition* (Reconnaissance d'entités nommées)

CER : *Character Error Rate* (Taux d'erreur de caractères)

LISTE DES TABLEAUX

Tableau 1: Comparaison des modèles de reconnaissance de la parole selon les métriques et leur temps relatif d'exécution.....	42
Tableau 2: Comparaison des modèles de reconnaissance de la parole selon les corpus LibriSpeech et SupremeCourt.....	43
Tableau 3: Comparaison des modèles de reconnaissance de la parole selon les longueurs de segment de dix ou trente secondes.....	45

1. INTRODUCTION

1.1 Contexte et problématique

Le traitement automatique du langage (TAL), également connu sous le nom de *natural language processing* (NLP), est un domaine qui rapproche informatique, linguistique, et intelligence artificielle. Ce secteur en croissance importante depuis déjà quelques décennies a pour objectif de transmettre la faculté de langage à l'ordinateur, alors qu'elle est historiquement propre à l'humain. Ainsi, on peut grâce à ces technologies s'attendre à ce que des machines soient capables de comprendre, de générer, mais également d'interpréter les signaux linguistiques, qu'ils soient écrits ou oraux. Ce champ contient de nombreuses applications très répandues, à savoir notamment la traduction automatique, l'analyse de sentiments, la génération de texte, ou encore le traitement automatique de la parole. Cette dernière application peut se diviser en deux catégories. Premièrement, le *text-to-speech* (TTS), qui consiste à générer de la parole en transformant des données textuelles en données audio. Secondement, le *speech-to-text* (STT), qui consiste à générer des transcriptions automatiques en transformant des données audio en données textuelles. Cette seconde application, également appelée **reconnaissance automatique de la parole** en français, est le plus souvent désignée sous le sigle ASR (*Automatic Speech Recognition*). C'est spécifiquement ce sous-domaine qui nous intéressera dans cette étude.

La reconnaissance automatique de la parole est primordiale pour accomplir certaines tâches, telles que l'assistance vocale, la dictée vocale, ou encore la transcription automatique de discours. Cette technologie connaît des avancées majeures depuis quelques années, puisqu'elle repose désormais beaucoup sur des méthodes récemment introduites telles que les réseaux neuronaux profonds et les modèles de type *transformer*. Les systèmes d'ASR connaissent ainsi une amélioration constante, du point de vue de leur précision et de leur robustesse, et peuvent traiter des données de plus en plus variées et volumineuses. Cependant, malgré ces progrès significatifs, de nombreux défis sont encore à relever afin de diminuer les biais algorithmiques tels que le sur-apprentissage ou la gestion de

l’homophonie. Afin d’améliorer les systèmes d’ASR, il faut savoir les évaluer de manière précise et objective. Pour cela, il existe des métriques, souvent issues de la traduction automatique, qui permettent de comparer une transcription humaine de référence à une hypothèse, c’est-à-dire au résultat généré. Mesurer la qualité des transcriptions générées permet de comparer les divers modèles étudiés et de trouver des idées d’amélioration.

La métrique la plus ancienne et la plus basique est le *Word Error Rate* (WER), qui calcule un taux d’erreur par mot entre la référence et l’hypothèse. Bien que son calcul soit simple, le WER connaît de nombreuses limites, liées entre autres à la sémantique et à la syntaxe. D’autres métriques mises au goût du jour, telles que le Semantic WER ou BLEU, utilisent des méthodes plus avancées et prennent en compte certains aspects linguistiques pour affiner leur résultat. Il devient important de nuancer l’analyse des transcriptions en fonction des données analysées et de ce qu’on cherche à obtenir. Dans ce mémoire, nous chercherons à étudier les méthodes d’évaluation des systèmes d’ASR, et par cela à comparer des systèmes variés, dans des contextes différents. Ce travail nous permettra éventuellement de proposer des recommandations concernant les pratiques d’évaluation dans ce domaine.

1.2 Outils utilisés

La première étape pour entreprendre un projet informatique de la sorte est d’établir quels outils utiliser. Cette section s’attache à brièvement introduire les ressources utilisées pour évaluer des systèmes de reconnaissance vocale. Nous décrirons ci-dessous, et dans cet ordre spécifique, les environnements de programmation exploités, les corpus de données, les modèles de reconnaissance vocale que nous étudions, et enfin les métriques d’évaluation. Nous décrirons plus longuement les modèles et les métriques dans la partie « cadre théorique », ainsi que les corpus dans la partie « méthodologie ».

Tout d’abord, nous avons rapidement établi que Python est le langage de programmation le plus adapté pour cette étude. Sa facilité d’utilisation couplée à sa compatibilité avec divers modèles d’ASR *open source* font que ce langage est très couramment utilisé dans la recherche dans ce domaine. De plus, de nombreuses

bibliothèques utiles sont proposées, particulièrement celles liées à l'apprentissage automatique telles que TensorFlow, PyTorch ou Keras, ainsi que celles dédiées au traitement du signal comme Librosa, PyDub ou wav. Enfin, ce qui rend Python si pratique est qu'il est utilisable sur des environnements de programmation adaptés aux projets de science des données. Nous avons profité des applications interactives Jupyter Notebook et Google Colab, qui s'exécutent cellule par cellule. Cette dernière, en plus d'être liée à Google Drive, donne accès à divers GPU pour un traitement plus efficace des données.

Par la suite, le choix des corpus était crucial, car ceux-ci déterminent notre angle d'analyse pour évaluer les modèles de transcription. Nous avons donc opté pour deux corpus différents, qui transmettent divers niveaux linguistiques. Premièrement, le corpus **LibriSpeech**, qui contient des lectures audio de livres. Secondement, le corpus **Oyez (Supreme Court)**, qui contient des enregistrements audio de la Cour Suprême des États-Unis. Chacun de ces corpus contient des fichiers de transcriptions humaines de référence, que nous avons dû aligner informatiquement avec l'audio qui correspondait. La nature même de ces ensembles de données les rend significativement différents. Les données de LibriSpeech sont propres et segmentées, celles de Oyez sont davantage bruitées et contiennent un langage spécifique. Nous avons divisé chaque corpus en *datasets* de longueurs différentes, puis en segments de durées variées.

En ce qui concerne les modèles de reconnaissance vocale, nous avons décidé d'en étudier six. Tout d'abord, **DeepSpeech** (2017), qui a fait partie des premiers modèles open source de *deep learning*, grâce aux réseaux neuronaux profonds. Ensuite, **Canary**, qui est un modèle de NVIDIA NeMo qui utilise également des réseaux neuronaux classiques. Et enfin, **Whisper**, **SeamlessM4T**, et **Wav2Vec2**, qui utilisent des *transformers*. On parle d'architecture Transformer lorsque le réseau de neurones crée des relations entre les données pour permettre de les traiter en parallèle, et non séquentiellement. Certains modèles ont des particularités importantes. Par exemple, Wav2Vec2 est basé sur un apprentissage auto-supervisé, tandis que Whisper est connu pour être compétent dans des contextes multilingues. Nous nous sommes assurés d'utiliser uniquement des fichiers wav pour l'audio, car ce type de fichier fonctionne pour chacun de ces modèles.

Enfin, l'évaluation des modèles repose sur des métriques fiables, entraînées autant que possible à reconnaître les divers contextes linguistiques. Comme expliqué précédemment, le calcul de taux d'erreur du **WER** est largement reconnu dans le milieu, mais il connaît ses limites. C'est pour cette raison que nous avons ajouté quatre métriques pour le compléter. Tout d'abord, et comme son nom l'indique, le **SemanticWER** ajoute un aspect sémantique à ce taux d'erreur, puisqu'il tolère les variations morphosyntaxiques tant que le sens est proche. D'une manière similaire, **METEOR** prend aussi en compte la sémantique, à travers la synonymie et les flexions. Ensuite, **BLEU** compare les n-grammes, c'est-à-dire des groupes successifs, de mots entre la référence et l'hypothèse. Enfin, la métrique la plus récente parmi notre inventaire est le **BERTScore**, qui utilise des *embeddings*, ou plongements lexicaux, provenant de LLMs (grands modèles de langage).

1.3 Objectifs

Ce mémoire a pour objectif d'étudier les méthodes d'évaluation des systèmes d'ASR. Nous nous intéressons spécifiquement aux divers points de comparaison qui se présentent à nous. En effet, nous avons à disposition six métriques à comparer entre elles en fonction de divers ensembles de données et diverses utilisations. L'accent sur les métriques, provenant de la traduction automatique, joue un rôle important dans notre analyse. Celles-ci nous permettent non seulement d'évaluer les systèmes selon plusieurs critères, mais également d'obtenir des résultats nuancés, et donc analysables.

Lors de notre étude, notre but principal était de mieux comprendre les subtilités propres aux outils étudiés. Nous avons ainsi cherché à dresser des avantages et défauts aux systèmes et aux pratiques, dans le but d'aboutir à des recommandations dans le milieu de la transcription automatique. Bien que les systèmes soient de plus en plus efficaces, il reste de très nombreuses pistes d'amélioration à prendre en compte. Nous espérons donc aider à éclaircir certaines zones d'ombre concernant ce sujet, afin de réfléchir aux usages et aux futurs développements des modèles d'ASR.

2. CADRE THÉORIQUE

Dans ce chapitre, nous définissons les concepts clés liés au domaine de l'ASR afin que nos explications postérieures soient comprises par tout le monde. Nous cherchons également à nous assurer qu'une connaissance commune existe entre tous les lecteurs, avant de plonger au cœur du sujet.

2.1 Enjeux de la reconnaissance automatique de la parole

Il existe de nombreux enjeux dans le domaine de la reconnaissance automatique de la parole. Nous donnerons ici les principaux, afin de dresser un panorama des questionnements actuels dans le domaine. Nous nous baserons sur la connaissance générale que nous avons acquise lors de nos lectures d'articles sur le domaine. Il existe bien évidemment de nombreuses autres problématiques que celles-ci.

Tout d'abord, les chercheurs souhaitent avant tout diminuer le taux d'erreurs dans les transcriptions automatiques. Si un système est précis dans des circonstances variées, on peut s'attendre à ce qu'il ait de nombreuses qualités. Ainsi, la précision est avant tout un indicateur que le modèle répond aux demandes, et présente un niveau élevé de compréhension sur les données sur lesquelles il s'applique. De l'autre côté, cela n'est utile que si c'est accompagné d'une diminution des coûts en temps et en argent. Idéalement, il faudrait que l'usage des systèmes puisse se répandre autant que cela est nécessaire, sans compromettre les performances.

Ensuite, on demande aux systèmes d'ASR qu'ils s'adaptent aux contextes différents aux variations non prévues, en maintenant des résultats stables. C'est ce qu'on appelle la robustesse. Cela concerne notamment l'audio contenant des bruits de fond, divers locuteurs, ou encore des accents variés. Par ailleurs, nous visons à éviter le sur-apprentissage, c'est-à-dire une spécialisation trop forte qui empêche le modèle de généraliser sur des données plus hétérogènes que celles qu'il connaît.

En plus de cela, les aspects grammaticaux de la langue doivent obligatoirement être pris en compte pour générer des transcriptions fiables. La sémantique est sans doute l'aspect qui intéresse le plus, que ce soit pour la reconnaissance de synonymes, l'identification d'entités nommées, ou pour créer une relation numérique entre les mots avec des *embeddings*. La syntaxe, la morphologie et la prosodie sont également d'autres exemples d'éléments à analyser. De façon analogue, les dispositifs d'ASR sont meilleurs s'ils peuvent s'adapter aux différents niveaux de langue.

Enfin, un dernier aspect non négligeable est celui de la diversité linguistique. Bien que dans cette étude nous nous pencherons uniquement sur des données en anglais, les systèmes d'ASR doivent tenter d'être multilingues autant que possible. De nos jours, la plupart des ressources linguistiques sont présentes en seulement quelques langues, ce qui crée un déséquilibre important, tout comme pour le domaine de la traduction automatique. De même, il est parfois nécessaire de s'adapter aux variantes dialectales pour répondre aux besoins des utilisateurs.

En conclusion, les enjeux principaux autour de l'ASR sont actuellement à peu près tous liés de près ou de loin à la **précision des transcriptions**. De fait, que ce soit pour rendre les modèles plus polyvalents linguistiquement, plus résistants aux bruitages, ou plus adaptés aux phénomènes sémantiques, les métriques jouent un rôle primordial dans l'optimisation des modèles. Pour faire simple, les modèles doivent idéalement aboutir à des scores les plus élevés possibles, pour un coût en temps et en argent le plus bas possible.

2.2 Présentation des modèles d'ASR

Dans cette section, nous définissons un à un les modèles d'ASR que nous avons utilisés. Pour chacun des modèles, nous partons d'une explication la plus triviale possible, pour essayer d'introduire des concepts plus avancés qui détaillent leur fonctionnement.

2.2.1 DeepSpeech

DeepSpeech, développé par l'entreprise chinoise Baidu entre 2014 et 2017, est un modèle d'ASR qui a été entraîné en apprentissage supervisé. Son développement s'est basé

sur un réseau neuronal récurrent (RNN), avec une architecture particulièrement simple. Ce système ne fait effectivement pas appel à des méthodes de traitement audio lourdes, telles que l'usage d'un dictionnaire phonétique ou la modélisation du bruit. DeepSpeech utilise originellement une architecture en cinq couches cachées, de chacune 2048 neurones. Ces couches servent à stocker des informations sur des périodes longues. C'est ce qu'on appelle un type LSTM (*Long Short-Term Memory*) de réseaux de neurones. La cinquième couche combine les sorties pour créer une prédiction contextuelle de manière complexe. Elle crée des vecteurs finaux des caractéristiques analysées par les autres couches, puis les envoie à la sortie *softmax* qui donne des réponses probabilistes. Tout comme pour Wav2Vec2, le modèle est entraîné grâce à la fonction de perte CTC, pour aider à émettre des transcriptions sans alignement. [\[2\]](#)

Afin d'entraîner ce modèle, ses auteurs ont fait usage de divers GPU pour accélérer son entraînement. Cela permet d'utiliser une parallélisation sur les données et sur le modèle. Un « *striding* », ou découpage temporel, de taille 2 est utilisé sur la couche récurrente ce qui réduit les calculs puisqu'on saute un échantillon audio sur deux. DeepSpeech a fait appel à une quantité conséquente de données annotées, à savoir 5000 h de parole lue de 9600 locuteurs différents. De plus, des corpus publics tels que le Wall Street Journal, Switchboard et Fisher ont aidé à rendre le modèle plus robuste. Des données volontairement bruitées ont été utilisées, ce qui force le modèle à prendre en compte l'effet Lombard. Ce phénomène désigne la modification de prononciation chez un locuteur lorsqu'il se situe dans un environnement bruyant. Enfin, le système inclut également un modèle statistique N-gram afin de favoriser les combinaisons courantes de mots. [\[2\]](#)[\[3\]](#)

2.2.2 Wav2Vec2

Le modèle Wav2Vec 2.0, développé par Facebook AI Research en 2020, se base sur un encodeur convolutif. Contrairement à sa première version, il utilise également un réseau Transformer, qui lui permet de modéliser les dépendances sur le long terme, et créer un contexte phonétique global. En premier lieu, il crée des représentations de la parole à l'aide d'audio non étiquetés, On dit pour cela que c'est un modèle en apprentissage auto-supervisé. Par la suite, il vient affiner cela sur des données qui ont été transcrites, notamment grâce à LibriSpeech et LibriVox. Il est donc censé être capable de faire de la

reconnaissance vocale avec seulement peu de données annotées. Cette qualité a de quoi être grandement intéressante, car les grands corpus transcrits ne représentent pas tous les contextes de langue. Tout particulièrement, beaucoup de langues n'ont pas du tout accès à ce type de corpus dont de nombreux modèles d'ASR dépendent. Wav2Vec2 a pour ambition de s'inspirer du processus cognitif de langage propre à l'humain. C'est pour cela qu'il cherche à créer une représentation de la langue avant même de s'aider de quelconque transcription. [4]

L'architecture de Wav2Vec2 contient un encodeur de caractéristiques, qui fonctionne comme un réseau neuronal convolutif multicouche, qui normalise les données audio brutes pour représenter la parole grâce au Transformer. Le Transformer contient des *embeddings* qui forment une information séquentielle, et cela est quantifié par des unités discrètes. Lors du pré-entraînement, certaines séquences sont cachées de manière aléatoire, et le modèle cherche à les prédire pour apprendre les représentations de manière robuste. Une dernière étape de *fine-tuning* est effectuée, dans laquelle une couche de projection est ajoutée dans le but de prédire des phonèmes ou des caractères à l'aide des transcriptions. On utilise alors une fonction de perte CTC (*Connectionist Temporal Classification*) qui s'occupe de l'alignement de l'audio avec les transcriptions. Wav2Vec2 existe dans deux versions. La version BASE qui contient 95 millions de paramètres, et la version LARGE qui en utilise 317 millions. [4][5]

2.2.3 Whisper

Le modèle en apprentissage supervisé Whisper a été développé par OpenAI et a été publié en 2022. Il a été entraîné sur 680 000 heures de transcriptions audio dont 117 000 heures dans une autre langue que l'anglais, et 125 000 heures pour une traduction d'une langue X vers l'anglais. Les données d'entraînement de Whisper sont particulièrement diversifiées, ce qui fait de lui une référence dans le domaine du traitement de la parole. Les fichiers audio ont été segmentés en morceaux longs de 30 secondes dans les données d'entraînement. Pour éviter d'induire en erreur les évaluations futures, ils effectuent un dédoublonnage sur les textes de transcription. Cela permet de réduire les redondances dans le contenu des données d'entraînement. Afin de s'assurer de la qualité des transcriptions, Whisper utilise un filtrage automatisé. Cela permet de détecter les transcriptions qui sont

déjà générées par machine, afin de les ignorer. Le risque serait que le modèle apprenne d'une manière non naturelle. Les auteurs du modèle appellent cela un apprentissage de type « transcript-ese », qui renforce les biais de la machine. Whisper peut utiliser également un détecteur de langue, pour s'assurer que la langue de l'audio et la transcription sont les mêmes. [16]

L'architecture de Whisper utilise un *Transformer* de type encodeur-décodeur, ce qui permet de traiter les données séquentiellement, et d'obtenir des prédictions plus adaptées au contexte. L'audio est rééchantillonné à 16 000 Hz, et un Mel spectrogramme de 80 canaux est calculé afin de représenter la répartition des énergies sonores. Le texte est traité grâce à un tokeniseur *Byte Pair Encoding* (BPE), qui a la particularité de fonctionner au niveau des octets. Le BPE était utilisé avant tout pour GPT-2, avant d'être adapté aux modèles multilingues. Whisper a un format multitâche, ce qui signifie qu'il peut effectuer plusieurs tâches sur un même signal audio : transcrire, traduire, aligner, identifier la langue, etc. Cela se produit grâce à des jetons qui spécifient entre autres quelle langue est parlée, quelle tâche à réaliser (<|transcribe|> ou <|translate|>), et s'il n'y a pas de parole (<|nospeech|>). Le système Whisper contient plusieurs modèles de tailles différentes : Tiny, Base, Small, Medium, Large. La version la plus longuement entraînée, Large V2, a été entraînée de manière à diminuer le sur-apprentissage. [16][17]

2.2.4 SeamlessM4T

SeamlessM4T est, en plus d'être un système de reconnaissance vocale, un outil de traduction et de synthèse vocale qui doit fonctionner pour une centaine de langues. Ce modèle *open source* développé par Meta, en 2023, se base sur l'utilisation de l'infrastructure de multi-encodeurs X2T. Celui-ci contient un encodeur de parole (Conformer) ainsi qu'un encodeur de texte (Transformer). SeamlessM4T est pré-entraîné avec w2v-BERT 2.0, lui-même étant un outil auto-supervisé qui encode la parole. Ce pré-entraînement, qui porte sur un million d'heures de corpus couvrant 143 langues, a pour but de générer des représentations solides de l'audio. Cela facilite par la suite les diverses tâches de SeamlessM4T, telles que la génération de transcriptions ou la traduction automatique. Nous pouvons donc nous attendre à ce que SeamlessM4T soit capable de généraliser ses données, ce qui augmente sa robustesse. [21]

En ce qui concerne la tâche d'ASR de SeamlessM4T, l'encodeur w2v-BERT 2.0 commence par encoder la parole. Par la suite, l'affinage contient deux phases distinctes. La première utilise des données audio et texte supervisées en anglais, tandis que la seconde apporte des données audio transcrites non anglophones. Dans tous les cas, ce sont des données de source ouverte, qui sont par la suite traitées par un filtrage sophistiqué. Ce filtrage est effectué de diverses manières. Les éléments qui ajoutent du bruit, tels que les caractères spéciaux et la ponctuation, ou encore les contenus toxiques, sont supprimés. Les séquences audio ne sont gardées que si elles correspondent à une certaine longueur. Un pseudo-étiquetage du modèle multilingue T2TT est également utilisé pour améliorer la qualité des données avant traitement. Par ailleurs, ce modèle s'est entraîné sur des données variées. Des données annotées humainement, dites « primaires », sont utilisées. De même, la méthode SeamlessAlign extrait des données parallèles supplémentaires, qui sont des données filtrées avec le système Sonar qui donne des scores aux alignements. Ce modèle existe sous deux configurations. La « Medium », qui contient 1,2 milliard de paramètres, et la version « Large » qui en utilise 2,3 milliards. [\[21\]\[6\]](#)

2.2.5 Canary

Le modèle Canary a été développé en 2024 par NVIDIA, et a été rendu *open source* en 2025, avec notamment la publication de la version Canary-1b-v2 sur Hugging Face en août. Ce modèle est de type encodeur-décodeur à attention basé sur une architecture de Fast-Conformer pour l'encodeur, ajouté à un Transformer pour le décodeur. En termes simples, son architecture permet d'extraire les informations audio de manière locale, puis de générer une transcription robuste contextualisée. Canary ne prend initialement en charge que l'anglais, le français, l'espagnol et l'allemand. Il supporte la transcription d'audio et la traduction automatique et surpasse les modèles les plus reconnus tels que Whisper et Seamless-M4T, alors qu'il n'est entraîné que sur 86 000 heures d'audio. Cela montre qu'une bonne architecture peut apporter des avantages à plusieurs niveaux comparé aux anciens modèles. Parmi ses autres qualités, Canary permet de réduire les hallucinations, c'est-à-dire la production de transcriptions lorsqu'il n'y a pas de parole. Enfin, la version récente de Hugging Face contient 978 millions de paramètres, trente-deux couches

d'encodeur et huit couches de décodeur. Il inclut désormais vingt-cinq langues sur lesquelles il a optimisé un tokeniseur. [\[14\]](#)

D'un point de vue plus technique, l'architecture de Canary est composée d'un Fast-Conformer de taille XL, basé sur des couches convolutionnelles pour extraire les informations audio locales, ainsi qu'un Transformer pour générer la transcription en s'aidant du contexte global. Le Fast-Conformer est un Conformer optimisé en rapidité avec une efficacité semblable. En effet, il multiplie son nombre de sous-échantillonnages par 8, pour une accélération d'un facteur de 2,8. Cet encodeur est ici initialisé par des poids pré-entraînés. Pour pallier au manque de données d'entraînement, les auteurs ont généré des données textuelles synthétiques pour la traduction de la parole. De plus, Canary utilise plusieurs techniques d'entraînement qui le rendent plus performant. Par exemple, un multiplexage stochastique pondéré est effectué pour équilibrer les données, lesquelles sont ensuite mélangées dynamiquement. De même, un regroupement d'énoncés de durée similaire est appliqué, ainsi qu'un affinage pour la robustesse face au bruit. Enfin, tout comme Whisper, Canary fait usage de jetons d'invite qui contiennent une information sur la langue d'entrée ou de sortie, ou encore sur la ponctuation ou la capitalisation. [\[14\]](#)[\[15\]](#)

2.3 Présentation des métriques

Dans cette section, nous définissons une à une les métriques que nous avons appliquées à nos transcriptions générées par les modèles. Pour chacune de ces métriques, nous partons d'une explication la plus triviale possible, pour essayer d'introduire des concepts plus avancés qui détaillent leur fonctionnement.

2.3.3 WER

Le WER (*Word Error Rate*), ou en français taux d'erreurs sur les mots, est basé sur la distance de Levenshtein, un algorithme purement mathématique représentant une distance entre deux chaînes de caractères. Cette métrique est devenue la référence pour comparer les systèmes d'ASR depuis les années 1980, une époque où les modèles statistiques tels que les chaînes de Markov étaient largement utilisés. Le but du WER est

donc d'obtenir un taux d'erreur de manière objective, logique, et surtout très simple. Cette métrique calcule la proportion d'erreurs de mots nécessaires pour transformer la transcription automatique en la référence correcte, basée sur la distance de Levenshtein. Son score se situe généralement entre 0 et 1, où 0 signifie une transcription parfaite (pas d'erreur), et plus le score augmente, plus la qualité est mauvaise. Son score peut éventuellement dépasser 1, car un mot dans la référence peut aboutir à plusieurs erreurs, s'il est remplacé par un groupe de mots. [\[13\]](#)

Le fonctionnement du taux d'erreur sur les mots est assez simple à comprendre. La méthode de Levenshtein, que le WER applique au niveau du mot et non du caractère, mesure le nombre d'opérations requises pour qu'une chaîne soit identique à une autre. Les opérations possibles sont les suivantes au nombre de trois. Premièrement, la substitution (S), qui consiste à remplacer un mot dans la séquence. Secondement, l'insertion (I), qui consiste à ajouter un mot dans la séquence. Enfin, la suppression (D), qui consiste à supprimer un mot dans la séquence. Bien que sa simplicité le rende très pratique, le WER ne prend pas en compte des aspects importants comme la sémantique ou la syntaxe. Cette métrique est par conséquent la plus simple à appliquer, mais aussi la moins précise. [\[13\]](#)

2.3.4 Semantic-WER

Le SWER, connu sous le nom de *SemanticWER* ou WER sémantique, est une extension du WER classique. Il a été publié en 2021 par le chercheur Somnath Roy. Le WER n'accordait traditionnellement pas de poids différents à chaque erreur, ce qui le rendait incapable de réellement expliquer si la transcription était fiable sémantiquement ou non. Le SWER est donc une version pondérée du WER qui attribue des poids sémantiques aux erreurs, pénalisant plus fortement les erreurs sur des mots-clés importants. Par exemple, une erreur sur un article sera moins pénalisante qu'une erreur sur un verbe. Celui-ci s'analyse par un score entre 0 et 1, où 0 indique une transcription sémantiquement fidèle, et 1 une transcription avec des erreurs sémantiques importantes. Comme pour le WER, son score représente une distance. [\[28\]](#)

Le WER sémantique conserve les méthodes de calcul de l'algorithme de Levenshtein, mais ajoute un poids unique à chaque erreur. Pour la substitution, les entités

nommées valent une pénalité de 1, tandis que ce score est réduit pour les autres termes, en fonction de plongements lexicaux. Les suppressions ont une pénalité plus forte pour les omissions de termes importants, et les insertions affectent moins le score que pour le WER simple. Ces diverses méthodes de pondération font que le SWER est davantage adapté aux besoins de la reconnaissance de la parole, et qu'il connaît une dimension sémantique que le WER classique ne connaissait pas. [\[28\]](#)

2.3.1 BLEU

BLEU (Bilingual Evaluation Understudy), est une métrique d'évaluation des systèmes créée par IBM Research en 2002. Elle est avant tout reconnue dans le milieu de la traduction automatique, où elle vise à comparer une traduction automatique avec une traduction humaine. Cette comparaison entre référence et hypothèse ne diffère pas de ce qui est recherché dans le domaine de l'ASR. Concrètement, le score BLEU mesure la qualité d'une traduction automatique en comparant les n-grammes de la traduction candidate avec ceux d'une ou plusieurs traductions de référence humaines, en tenant compte d'une pénalité de brièveté pour éviter les traductions trop courtes. Son score est généralement compris entre 0 et 1 (parfois exprimé en pourcentage 0%-100%), où 1 signifie une très bonne correspondance avec la référence (meilleure qualité), et 0 une très mauvaise. De manière réaliste, le score s'approche rarement de 1, car les variations sont naturelles et ne représentent pas forcément une erreur. [\[20\]](#)

Sur le plan technique, BLEU utilise une comparaison entre les n-grammes, c'est-à-dire les séquences de mots. Il tente de ne pas surévaluer une transcription qui répéterait une séquence de mots, quand bien même celle-ci serait correcte. Il utilise une moyenne géométrique entre les résultats des divers n-grammes, jusqu'au 4-gramme, ce qui permet une analyse juste et équilibrée. À cela s'ajoute une pénalité de brièveté, à laquelle on a recours pour diminuer le score des traductions ou transcriptions plus courtes que la référence. Cette approche connaît ses limites, car elle ignore tout l'aspect sémantique, au profit d'une précision lexicale stricte. [\[20\]](#)

2.3.2 METEOR

La métrique METEOR (Metric for Evaluation of Translation with Explicit Ordering), a été développée en 2005 par des chercheurs de l'université Carnegie Mellon (CMU). Son objectif principal est de dépasser les performances du score BLEU. Cette mesure cherche à prendre en compte la synonymie, les spécificités morphologiques, et l'ordre des mots pour améliorer les résultats. En effet, METEOR évalue la traduction en faisant un alignement mot à mot entre la traduction candidate et les références selon des correspondances exactes, morphologiques ou synonymiques, puis ajoute certaines mesures pour se calculer en fonction d'une correspondance sémantique et syntaxique. Son score est représenté entre 0 et 1, où 1 représente une correspondance quasi parfaite avec la référence, et 0 une mauvaise qualité. [\[12\]](#)

Techniquement, METEOR effectue un alignement sur les unigrammes, soit mot à mot, dans le but de créer une hiérarchie des correspondances. En haut de la hiérarchie, on retrouve les mots qui sont strictement identiques. Un peu plus bas, il y a ceux qui partagent une même racine (*stemming*), et plus bas encore les synonymes. Par la suite, on évalue la qualité de cet alignement grâce à la précision et au rappel, selon si on retrouve ou non les mots de la référence dans l'hypothèse. Une moyenne harmonique pondérée crée un score global entre les deux calculs, en mettant une plus grande importance sur le rappel. Enfin, METEOR applique une pénalité de fragmentation, qui sert à valoriser un bon ordre des mots. Pour tout cela, cette métrique est censée être plus proche du jugement humain que BLEU. [\[12\]](#)

2.3.5 BERTSCORE

La métrique BERTScore a été introduite par des chercheurs à Cornell University en 2019. Elle utilise le modèle de langage pré-entraîné BERT (*Bidirectional Encoder Representations from Transformers*) afin de créer des représentations contextuelles des mots. C'est ce qu'on appelle des *embeddings* ou plongements lexicaux. BERTSCORE compare donc les *embeddings* contextuels des mots dans la phrase candidate et la ou les phrases de référence en mesurant leur similarité cosinus, sans se limiter à une correspondance exacte des mots, pour capturer la profondeur sémantique. On cherche donc à évaluer la proximité de sens entre les deux textes grâce à une représentation vectorielle.

Son score est compris entre 0 et 1, avec 1 indiquant une forte similarité sémantique et 0 une faible similarité. [\[29\]](#)

Le calcul du BERTScore suit en réalité diverses étapes. Tout d'abord, chaque mot de la référence et de l'hypothèse devient un vecteur pour créer un plongement lexical. Une similarité cosinus entre paires de mots est calculée, ce qui permet d'associer les mots du candidat à son mot le plus proche dans la référence. C'est ce qui se nomme le « *greedy matching* ». Grâce à BERT, on peut ensuite appliquer une précision, un rappel, et une F-mesure. Par la suite, on affine cette évaluation en lui appliquant la fréquence inverse des termes, ou IDF (*Inverse Document Frequency*). Cela donne une importance aux mots rares, qui sont considérés plus significatifs d'un point de vue sémantique à l'échelle du texte. Ainsi, le BERTScore cherche à évaluer la qualité sémantique globale, et donc obtient un résultat basé sur le contexte large, et non sur des aspects sémantiques isolés. [\[29\]](#)

3. ÉTAT DE L'ART

Tout au long de ce chapitre, nous nous efforcerons de présenter l'état des connaissances dans le domaine de la reconnaissance de la parole. Nous décrirons les pratiques actuelles, puis nous détaillerons les informations qui ressortent des articles sur les modèles.

3.1 Usages et travaux récents

Les techniques de reconnaissance de la parole sont rapidement adoptées suite à leur développement. Un exemple frappant est celui de l'industrie de l'automobile, qui intègre ces outils de nombreuses manières différentes. Les applications dans ce domaine concernent principalement la navigation GPS vocale, la gestion des appels téléphoniques ou encore la commande multimédia embarquée. Plus généralement, les demandes d'amélioration du confort de conduite poussent les entreprises à proposer un maximum de fonctionnalités modernes, or le traitement de la parole est une science moderne. De même, nous retrouvons ces technologies sur nos téléphones à travers les assistants vocaux, ainsi que sur les enceintes connectées et autres appareils domestiques high-tech. L'époque moderne met effectivement beaucoup en avant les interactions humain-machine. Grâce aux méthodes d'**apprentissage profond**, les tâches de traitement de la parole sont de plus en plus avancées. Les systèmes sont capables de s'adapter au contexte et de répondre aux questions de leur utilisateur, ce qui rend la machine plus crédible pour le consommateur. Effectivement, ce domaine connaît un progrès constant. Il y a quelques années, ces systèmes ne permettaient que d'exécuter des commandes. Cependant, en 2025, les utilisations de l'ASR permettent des dialogues naturels complets, même avec du bruit ambiant. Les progrès récents des divers domaines liés à l'intelligence artificielle ou au traitement automatique du langage aident à commercialiser les systèmes vocaux rapidement, et à rendre leurs usages plus fluides. Tout cela contribue à habituer la population à ces outils, et donc à renforcer la confiance dans leur utilisation, et ainsi à aboutir à une utilisation grand public. [\[22\]](#)

Les moteurs de reconnaissance de la parole modernes ont tendance à combiner les méthodes déjà connues pour créer des systèmes complexes plus adaptés à nos besoins. Cela améliore les résultats, que ce soit en termes de précision ou de vitesse de traitement. Les modèles les plus récents font appel à des architectures hybrides, qui utilisent généralement un apprentissage supervisé et des réseaux de neurones en apprentissage profond. Ce type de modèle est capable de comprendre les nuances linguistiques de manière fine, dans des circonstances variées. Les éventuelles perturbations acoustiques rencontrées posent désormais moins de problèmes grâce à cela. Naturellement, des modèles plus performants permettent une utilisation dans les domaines publics, tels que la santé ou la sécurité. Dans le milieu médical, certaines opérations sont facilitées grâce à ces technologies. Par exemple, les dictées des notes cliniques et l'enregistrement électronique des diagnostics optimise la gestion administrative. Ce gain de temps rend le travail des professionnels plus agréable. De plus, des analyses vocales automatiques permettent parfois de détecter des signes précoces de troubles tels que la dépression. Par ailleurs, dans les domaines de la justice et de la sécurité publique, les systèmes vocaux simplifient les prises de notes et assurent une transcription en temps réel des débats ou interrogatoires. Cela peut aider à améliorer la fiabilité et l'accessibilité des documents juridiques, ainsi que la rapidité d'exécution. En revanche, certaines critiques vis-à-vis de la confidentialité doivent être prises en compte. Ces exemples illustrent comment l'amélioration des systèmes les rends plus aptes à des utilisations professionnelles. [7]

Les avancées récentes en ASR sont dues aux nouvelles méthodes et approches employées grâce à la recherche scientifique dans le *deep learning*, ou apprentissage profond. Parmi les avancées majeures, nous bénéficions tout d'abord de l'apprentissage par renforcement. Cette approche consiste à optimiser les décisions de la machine en fonction des interactions avec l'environnement. Cela offre la possibilité d'une amélioration continue des systèmes, en adaptant simplement les paramètres mis en entrée. De façon similaire, la multiplication des découvertes permet un transfert d'apprentissage important. Les modèles déjà pré-entraînés sont réutilisés pour en concevoir des nouveaux plus efficacement. Une autre technique importante est celle de l'apprentissage fédéré, de par laquelle les modèles sont entraînés collaborativement, sur des données différentes et variées. En outre, les réseaux de neurones récurrents (RNN) sont capables de traiter des séquences audio temporelles de manière efficace, particulièrement grâce à la mémoire longue à court-terme

(LSTM). Ce type spécifique de réseau neuronal est conçu pour mémoriser des informations sur des longues périodes, ce qui est utile pour de grands jeux de données. Par ailleurs, les *transformers* et *embeddings* contextuels sont des architectures qui enrichissent les représentations sémantiques des modèles, dans le but de saisir les nombreuses nuances linguistiques propres au langage naturel. Similairement, l'usage de systèmes multimodaux offre une robustesse accrue, en combinant par exemple les signaux vocaux avec des informations visuelles ou biométriques. Ces innovations aboutissent à des transcriptions de plus en plus riches, et des analyses linguistiques de plus en plus avancées. Cela ouvre la voie à des avancées dans de nombreux milieux. De nombreuses difficultés restent à être surpassées, tels que la détection des changements de locuteur et la gestion d'enregistrements de faible qualité. [\[11\]](#)

Enfin, les métriques d'évaluation jouent un rôle central dans le développement des systèmes en reconnaissance automatique de la parole. Le déploiement de ces technologies est rendu possible grâce à des indices de qualité fiables. Afin de juger des performances d'un moteur de génération de transcriptions, nous devons quantifier rigoureusement la justesse des résultats. Les chercheurs ont pour objectif de parvenir à des comparaisons objectives entre les modèles, en fonction de contextes d'application nettement variés. La pertinence d'un dispositif est dépendante de l'objet d'étude exact. Le choix des critères de performance est essentiel pour cela, en ce qu'il donne la possibilité d'orienter l'analyse vers les aspects souhaités. Parmi les critères les plus courants, nous pouvons citer la fiabilité des transcriptions, l'adaptabilité aux divers contextes linguistiques, ou encore la résistance aux perturbations sonores. Ainsi, les différentes métriques peuvent effectuer des mesures sous des angles variés. Dans la pratique, de nombreux chercheurs considèrent que les standards d'évaluation sont plus efficaces s'ils sont utilisés de manière complémentaire. Effectivement, certaines sont plus aptes à exprimer une précision brute en fonction de la morphologie, tandis que d'autres utilisent des méthodes d'analyse de contexte sémantique, et d'autres encore prennent particulièrement en compte les aspects syntaxiques. Pareillement, les corpus de référence et les démarches de contrôles normalisés fixent une vision commune, en assurant que les évaluations soient reproductibles, donc comparables à tout moment. Il convient cependant d'évoquer les limites persistantes à ce jour. Les biais linguistiques, les difficultés d'adaptation au registre, ou encore les différences liées au

domaine d'application sont des éléments qui valent la peine d'être mesurés constamment. [\[23\]](#)

3.2 Affirmations des auteurs des modèles et résultats obtenus

Maintenant que nous possédons un certain niveau de connaissance concernant les modèles étudiés, nous allons vous présenter ce que les auteurs en disent dans leurs articles respectifs. Nous nous intéresserons à expliquer ce que les auteurs promettent en ce qui concerne la qualité de leur modèle. Nous préciserons ensuite quels résultats prometteurs ils ont déjà obtenus.

3.2.1 DeepSpeech

Selon Awni Hannun et al., leur modèle Deep Speech se distingue avant tout grâce à son architecture simplifiée. Il n'utilise pas de modules spécifiques pour la gestion du bruit ou des locuteurs, ni de dictionnaire de phonèmes. Au lieu de cela, il effectue un apprentissage de bout en bout grâce à des réseaux neuronaux récurrents (RNN), adaptés à l'optimisation des GPU. La parallélisation est améliorée grâce à des schémas spécifiques de partitionnement, et le RNN est simplifié pour éviter les lourdeurs. Cette approche nécessite cependant des ensembles de données annotées très volumineux. C'est pourquoi des méthodes de parallélisation sont utilisées, tel qu'un découpage temporel et des pas de décalage pour le traitement des couches convolutives. [\[2\]](#)

En termes de performances, DeepSpeech a notablement obtenu un WER de 16,0 % sur la totalité du test Switchboard Hub5'00, atteignant alors le meilleur résultat publié en 2014 à sa sortie. Les auteurs du modèle ont également créé un corpus contenant des séquences enregistrées dans des environnements bruyants, et obtenu un WER de 19,06 %, tandis que les autres modèles commerciaux atteignaient des scores allant de 30,47 % à 43,76 %. En dernier lieu, ajouter des bruits de synthèse lors de l'entraînement améliore le taux d'erreur, qui passe de 28,7 % à 22,6 %. Ce bruit synthétique artificiel rend effectivement DeepSpeech plus robuste aux bruits ambiants. [\[2\]](#)

3.2.2 Wav2Vec2

Selon Alexei Bævski et al., leur modèle Wav2Vec 2.0 a comme qualité principale d’être auto-supervisé, et donc de pouvoir apprendre des représentations robustes directement grâce à de l’audio brut, sans passer par un étiquetage des données. Cet apprentissage fait ensuite l’objet d’un transfert, pour recréer des données de supervision, et ainsi aboutir à des performances élevées malgré une méthode légère. Effectivement, le modèle fonctionne correctement, même lorsqu’il n’est entraîné que sur très peu de données présentant des annotations. Cette méthode est rendue efficace à l’aide d’un apprentissage d’unités discrètes de la parole, et de représentations contextuelles. Enfin, Wav2Vec 2.0 a une capacité de reconnaissance des sons particulièrement avancée, et peut donc également prendre en entrée de nombreuses données étiquetées si nécessaire. [4]

Les résultats obtenus qui nous intéressent pour Wav2Vec2 sont ceux testés sur sa version LARGE. Ses résultats de 1,8 % (*clean*) et 3,3 % (*other*) de WER sont devenus l’état de l’art sur LibriSpeech-960, grâce à un pré-entraînement sur LV-60k. Ce modèle est également performant pour les petits tests, et atteint notamment un WER de seulement 4,8 % pour l’ensemble du dataset *test-clean*, avec uniquement 10 minutes de données étiquetées. Par ailleurs, sur le corpus TIMIT, contenant des descriptions détaillées des phonèmes, le taux d’erreurs sur phonème (PER) est de 7,4 (*dev*) et de 8,3 (*test*). Cela dépasse largement tous les autres modèles étudiés, y compris la première version de Wav2Vec. [4]

3.2.3 Whisper

Selon Alec Radford et al., leur modèle Whisper représente une avancée majeure en ce qui concerne le traitement automatique de la parole, et ce car leur méthode présente de nombreux avantages. Tout d’abord, le système peut fonctionner en « *zero-shot* », c’est-à-dire sans nécessiter de réglages supplémentaires pour fonctionner. Par exemple, il n’y a pas besoin de le ré-entraîner ou de l’ajuster en fonction de la langue. Le modèle peut même traduire une langue vers l’anglais. Il est capable de généraliser ses connaissances pour être utilisé dans des environnements variés. En d’autres termes, il est prêt à l’emploi, en plus d’atteindre une précision peu éloignée des performances humaines. De plus, puisque

Whisper contient diverses versions plus ou moins importantes de son modèle, il est présenté comme flexible. Il est plus efficace pour les versions plus grandes, et graduellement plus compétent lorsque les données d’entraînement sont plus volumineuses. Plus notablement, les versions « large » sont capables de mutualiser leur connaissance entre les langues, et entre les diverses tâches. Ce transfert de connaissance améliore davantage le modèle. Enfin, et contrairement aux systèmes basés sur une auto-supervision, Whisper ne passe pas par des étapes de normalisation afin de générer du texte, ce qui simplifie sa structure. [16]

Les scores de Whisper sont présentés en taux d’erreur sur les mots pour évaluer la reconnaissance de la parole, et en BLEU pour mesurer la traduction automatique. Whisper Large V2 obtient un WER de 2,7 % sur *LibriSpeech test-clean* en *zero-shot*, réduisant ainsi les erreurs par rapport aux modèles entraînés directement sur ces données, y compris en ajoutant un bruit fort à moins de 10 décibels d’écart avec le signal audio utile. La performance du modèle est corrélée avec la quantité de données à 83 %. Pour cette raison-là, le WER se divise par deux lorsqu’on multiplie la taille des données par 16. De plus, Whisper atteint un nouvel état de l’art en traduction vocale d’une langue X vers l’anglais, avec un score de 29,1 BLEU. Enfin, Whisper présente également des résultats plus élevés que NVIDIA STT pour des transcriptions de longue durée sur divers ensembles de données, et une version Large V3 existe désormais. [16]

3.2.4 *SeamlessM4T*

Selon Loïc Barrault et al., leur modèle SeamlessM4T est le tout premier système d’ASR à permettre, en un système unifié, des traductions de manière multimodale entre l’audio et le texte. Ce système de bout-en-bout surpasse les structures classiques, en cascade. Ce modèle est présenté comme particulièrement robuste au bruit ambiant, et adapté à supporter les variations de locuteurs. L’équipe promet également une réduction dans la génération de contenu considéré toxique dans les traductions. Ainsi, ce modèle est censé présenter des performances plus élevées que les modèles en cascade, et être capable de générer des traductions audio vers texte (S2TT), texte vers audio (T2ST), texte vers texte (S2ST), et audio vers audio (S2ST) pour de nombreuses langues. [21]

En ce qui concerne les capacités du modèle SeamlessM4T, de nouveaux standards de performance sont atteints. Tout d’abord, un nouvel état de l’art est atteint en BLEU sur les données multilingues Fleurs. En S2TT, BLEU augmente de 4,2 points, soit 20 % de plus comparé aux meilleurs systèmes. En S2ST, cette augmentation est de 2,6 points comparé aux meilleurs modèles en cascade, ce qui représente une amélioration de 11,2 %. Par ailleurs, ce modèle atteint des scores XSTS supérieurs à quatre sur cinq pour vingt-quatre langues différentes, ce qui montre une correspondance avec le jugement humain. Les auteurs ont également comparé leur modèle et Whisper-Large-V2 sur 77 langues différentes. Le modèle a obtenu un WER moyen de 23,1 %, contre 41,7 % pour Whisper. Pour finir, SeamlessM4T atteint un score BLEU 7,4 points plus élevé que AudioPaLM-2-8B-AST en moyenne, sur trente-quatre langues à faible ressources traduites vers l’anglais. [\[21\]](#)

3.2.5 Canary

Selon Krishna C ; Puvvada et al., leur modèle Canary est capable d’atteindre des performances au moins aussi bonnes que les modèles de traduction automatique modernes, en utilisant seulement des données pseudo-étiquetées. L’entraînement du modèle a duré moins de quarante-huit heures, en bénéficiant du GPU ultra-performant A100 80GB de NVIDIA. Cela peut être considéré comme un exploit si nous prenons en compte les exigences phénoménales de ressource des autres modèles. Cette rapidité de traitement est rendue possible notamment grâce à une initialisation efficace de l’encodeur audio ainsi que l’usage d’un *bucketing* dynamique. Cette dernière pratique est une technique d’optimisation qui consiste à ranger les séquences d’audio par longueur ce qui réduit le remplissage inutile. Par ailleurs, les auteurs soulignent que Canary a des capacités élevées de généralisation des données en anglais. Des performances élevées peuvent être atteintes sur des données très différentes de celles d’entraînement. Enfin, le modèle utilise des données audio non vocales pour mieux détecter la présence ou l’absence de la parole, et donc empêcher les hallucinations. [\[14\]](#)

Les scores obtenus par Canary mettent en évidence la crédibilité des promesses des auteurs. Pour les tâches d’ASR multilingue dans ses quatre langues de prédilection, son

WER est plus bas que Whisper et SeamlessM4T dans dix tests sur douze. Il atteint en effet un moyenne un taux d'erreur de 6,20 % en anglais, 6,27 % en allemand, 4,09 % en espagnol et 5,39 % en français. Pour la traduction parole-texte automatique, la version Large de SeamlessM4T maintient des scores BLEU légèrement plus performants dans la plupart des tests, mais Canary obtient les meilleurs résultats comparé à des modèles de taille similaire. Il obtient également des résultats comparables voire meilleurs que Whisper-Large-v3 sur FLEURS et CoVoST-2. Il produit en plus de cela 16,7 % moins de caractères hallucinés que cette version de Whisper. Enfin, en ce qui concerne les données de longue durée, il obtient le WER le plus bas, avec 4,68 % pour Tedlium3. [\[14\]](#)

3.3 Autres outils performants

Il existe bien d'autres outils performants que nous ne pourrions malheureusement pas étudier dans ce mémoire, car cela rendrait notre travail trop complexe, et les analyses bien plus longues. Nous donnerons ici brièvement quelques exemples de modèles et de métriques réputés qui n'ont pas fait partie de notre sélection, notamment car certains de ces modèles ne sont pas *open source*, ou parce que les métriques ne proviennent pas de la traduction automatique.

Premièrement, en ce qui concerne les modèles, plusieurs se sont distingués récemment, que ce soit pour une robustesse particulièrement élevée ou bien pour des capacités multitâches. Le modèle **XLSR-53**, par exemple, qui est un dérivé de Wav2Vec2 que nous étudierons. Il a été pré-entraîné sur plus de cinquante langues, et est devenu une référence pour le traitement audio pour des contextes multilingues [\[1\]](#). Par ailleurs, **Chirp** de Google est entraîné sur environ douze millions d'heures d'audio, sur plus de trois cents langues. Ses résultats dépassent largement ceux de Whisper, notamment pour des langues à faible ressources [\[9\]](#). Enfin, il existe d'autres approches, qui cherchent une précision extrêmement élevée pour de l'audio très peu bruité. L'architecture hybride multistream **CNN** et **SRU** auto-attentionnel peut atteindre un WER de 1,75 % sur LibriSpeech test-clean, à l'aide de techniques provenant de modèles de langage [\[26\]](#). Ces alternatives seraient intéressantes à étudier dans un travail plus conséquent, mais nous en sommes restés aux modèles les plus caractéristiques.

Secondement, certaines métriques modernes ont des avantages particuliers qu’il pourrait être intéressant d’exploiter si on ne se limitait pas aux métriques de type WER ou provenant de la traduction automatique. La métrique **SeMaScore** est par exemple adaptée aux données transcrites bruitées, et mélangeant un taux d’erreur et une similarité sémantique. Il est également nettement plus rapide à calculer que le BERTScore [10]. Par ailleurs, l’approche présentée par la métrique **H_eval** est innovante. Celui-ci associe une distance sémantique à une mesure des erreurs sur les mots à faible importance sémantique. Il peut être environ cinquante fois plus rapide que BERTScore, tout en ayant une corrélation correcte avec les systèmes d’ASR [8]. De manière plus originale, et cela n’était pas nécessaire dans notre cas, la métrique **NoRefER** permet d’obtenir une évaluation des transcriptions générées sans utiliser de référence [27]. Enfin, il a récemment été introduit l’initiative **ASR-FAIRBENCH** qui pondère les performances selon des groupes démographiques, dans la perspective de créer un critère d’évaluation plus juste et plus éthique [30]. Nous pouvons évidemment nous attendre à ce que de nouveaux outils apparaissent dans les années qui vont suivre.

4. MÉTHODOLOGIE

Dans cette partie, nous exposerons le déroulement précis de notre réalisation du projet, étape par étape. Tout d’abord, nous expliquerons nos sélections de ressources de travail, afin d’introduire les corpus et de donner des justifications qui expliqueront clairement nos objectifs. En second lieu, nous décrirons la préparation des données, en mentionnant le prétraitement et l’alignement pour les rendre exploitables. Par la suite, nous détaillerons nos méthodes de création du pipeline qui applique les divers modèles sur les corpus. Enfin, nous reviendrons sur les procédés effectués pour évaluer ces systèmes.

4.1 Sélection des ressources

4.1.1 Description du corpus LibriSpeech

Le corpus anglophone LibriSpeech a été conçu par Panayotov et al. pour la recherche en reconnaissance automatique de la parole. Il est important pour nous d’inclure un corpus qui permet un point de comparaison avec les travaux d’autrui. Cette ressource fait usage d’environ 1 000 heures de fichiers FLAC d’enregistrements de livres audio présents dans le domaine public, à savoir le projet LibriVox. Ses transcriptions en format TXT sont alignées au niveau du mot, et segmentées en phrases courtes, ce qui rend son utilisation particulièrement pratique. Ses données sont très peu bruitées de par la nature de ces enregistrements, et sont présentées en sous-ensembles dédiés notamment à l’entraînement et au test des modèles, ce qui aide à reproduire les résultats des expériences. LibriSpeech joue un rôle majeur dans la recherche en ASR. [\[19\]](#)

Par ailleurs, les auteurs de ce corpus apportent des informations supplémentaires sur ce corpus. Tout d’abord, le corpus est censé être large et diversifié, grâce à la collecte de données libres de droit. Des techniques robustes de traitement du signal ont été appliquées pour aligner les segments d’audio avec leurs transcriptions. Deux structures de corpus existent : le « clean », qui contient des enregistrements nettoyés, et le « other », contenant du bruit ou d’autres perturbations. Les segments sont rangés par dossier afin de

trier par orateur. D'autres métadonnées sont présentes, notamment le nom du livre et le chapitre, pour simplifier l'analyse. Enfin, l'architecture de LibriSpeech est faite de telle sorte à permettre des expériences multi-tâches, incluant la reconnaissance de locuteur et la synthèse vocale. [18]

4.1.2 Description du corpus Oyez de la Cour Suprême

La ressource numérique Oyez présente des données publiques d'enregistrements de la Cour Suprême des États-Unis. Elle contient donc des transcriptions, des résumés et enregistrements d'audiences au sein de cette institution juridico-politique. Ces données ne sont initialement pas publiées pour le domaine de la reconnaissance de la parole, mais simplement pour garantir une transparence vis-à-vis du public. Les transcriptions sont détaillées, en ce qu'elles présentent des métadonnées telles que les divers noms des interlocuteurs ou la date d'enregistrement. Ce type de ressource présente une forte utilité dans la recherche liée à la justice, ce qui oriente les discours d'un point de vue linguistique. [25]

Le site qui présente cette ressource numérique propose également un corpus dédié aux tâches d'ASR. Des chercheurs ont effectué un travail pour la diarisation des locuteurs et la génération de transcriptions sur le corpus audio proposé par Oyez. Ils reconnaissent que ces tâches peuvent être assez complexes sur un tel corpus, et notamment que le développement de méthodes d'alignement peut-être nécessaire. Les enregistrements contiennent diverses voix, parfois en simultanées, et qui confondent juges, avocats, et témoins. Ce corpus contient des données audio riches linguistiquement, mais avec un lexique spécifique au domaine juridique. Le travail de ces chercheurs a abouti au développement de systèmes d'ASR adaptés à ce type de langage. Au moment de notre obtention du corpus nous avons recueilli quatre-vingt-cinq épisodes tous d'environ une heure. [24]

4.1.3 Choix des modèles

En ce qui concerne les modèles, nous en avons sélectionné un nombre restreint, ce qui permet une analyse un minimum approfondie. Notre objectif était de dresser un groupe prototypique, qui représente plus ou moins l'état global des outils d'ASR. Nous souhaitons également nous concentrer sur des systèmes *open source*, qui ont chacun fait l'objet d'une publication scientifique et dont le code source est disponible sur GitHub ou Hugging Face. C'est pourquoi nous avons choisi d'inclure les cinq modèles suivants : DeepSpeech, Wav2Vec2, Whisper, SeamlessM4T, et Canary. Leur diversité rend l'analyse contrastive pertinente.

Au-delà d'un choix uniquement éclairé par une simplicité d'utilisation, nous avons réfléchi à des éléments techniques qui pouvaient justifier leur usage. Tout d'abord, DeepSpeech représente l'ancien état de l'art, aujourd'hui considéré dépassé. Il ne s'appuie pas sur un pré-entraînement massif, mais plutôt sur une approche séquentielle classique, en analysant les données une à une, dans l'ordre. Il sert ici de point de comparaison avec les autres modèles. Le suivant, Wav2Vec2, marque une rupture en termes de méthodes, puisqu'il utilise un paradigme d'auto-supervision, exploitant de vastes corpus audio non annotés. Il utilise également un Transformer, avec lequel il cherche à créer une représentation contextuelle globale. Il illustre une rupture, plus performant que DeepSpeech, mais souvent moins que les suivants. Par la suite, Whisper s'est imposé comme un modèle de référence. Ce modèle est dit « fondationnel », à savoir qu'il a été entraîné sur des données multilingues volumineuses, dans le but de transcrire, mais aussi de traduire vers l'anglais et d'identifier la langue. Il est, de plus, reconnu pour sa robustesse, une qualité que nous chercherons à mettre en évidence. Dans la continuité de cette évolution, SeamlessM4T est également multilingue, mais il inclut un aspect multimodal. Il est en effet capable de traiter des données aussi bien audio que textuelles, et il permet de faire des tâches comme la traduction automatique ou la génération d'audio. Nous l'avons sélectionné pour sa popularité et ses performances. Enfin, Canary a été entraîné sur moins de données que Whisper et SeamlessM4T, mais il est pourtant l'état de l'art dans les quatre langues qu'il couvre. La version Canary-1b-v2 de ce modèle a été publiée en *open source* sur HuggingFace le 14 août 2025.

4.1.4 Choix des métriques

Pour ce qui est des métriques, nous souhaitons également bénéficier d'un ensemble complémentaire, relativement restreint. Il était particulièrement important d'évaluer nos modèles sur des critères hétérogènes, certains purement mathématiques, d'autres concentrés sur un aspect linguistique précis, et d'autres encore cherchant un contexte plus profond. Nous avons pour cela choisi d'utiliser WER et SemanticWER, qui sont deux métriques de taux d'erreurs, ainsi que BLEU, METOR et BERTScore. Ces trois dernières connaissent une forte réputation, car elles proviennent initialement du domaine de la traduction automatique.

Puisque les modèles d'ASR étudiés présentent chacun des avantages et des défauts, il était nécessaire de s'assurer que notre ensemble de métriques soit capable d'offrir une observation complète de leur performance. Pour commencer, nous devons évidemment inclure le WER, qui est la référence dans le domaine de l'ASR depuis les années soixante-dix. Il est reconnu pour sa simplicité algorithmique et permet de comparer les résultats avec ceux d'anciennes études. Cette méthode d'évaluation est cependant la seule de notre sélection à ignorer tout aspect grammatical, ainsi que l'ordre des mots. C'est pourquoi, nous avons décidé d'inclure également une version améliorée, le SemanticWER. Nous souhaitons évaluer dans quelle mesure cette métrique avec pondération sémantique vectorielle représente un pas en avant comparée à sa version précédente, purement mathématique. Par la suite, nous devons sélectionner des métriques provenant du domaine de la traduction automatique. Nous pouvons considérer effectivement qu'une transcription revient à une traduction écrite d'un signal audio, et qu'utiliser de telles métriques présente quelques avantages non négligeables. Effectivement, elles ont déjà prouvé leur efficacité dans la comparaison d'un texte d'hypothèse avec un texte de référence. Elles ont également un intérêt particulier, puisqu'elles intègrent à elles trois des dimensions grammaticales variées. Premièrement, BLEU, référence dans la traduction automatique, transmet une fidélité lexicale stricte basée sur des séquences de mots. Il sert de métrique simple pour évaluer la précision lexicale. Secondement, METEOR tient compte de la synonymie et des variations lexicales et morphologiques. Il a été conçu pour améliorer les résultats de BLEU, donc il devrait être plus fiable mais moins opaque. Enfin, la métrique BERTScore est la plus moderne. Elle crée des représentations sémantiques contextuelles

grâce à BERT, modèle de langage pré-entraîné. Nous supposons que cette métrique serait donc la plus proche des jugements humains.

4.2 Prétraitement et alignement des données

Une fois avoir établi quels outils nous souhaitions utiliser, nous avons été amenés à passer à l'étape de mise en pratique, à commencer au niveau des corpus. En effet, avant de se pencher sur la conception d'algorithmes et de chaînes de traitement pour faire usage des modèles d'ASR, nous devons tout d'abord effectuer un travail sur les données. Cette phase possède toute son importance, car le bon fonctionnement de ces systèmes dépend en grande partie de la qualité des données. Nous expliquerons dans cette section les quelques manières dont nous avons exploité les données téléchargées.

Avant d'en venir à utiliser les données des corpus, une étape préalable de normalisation des fichiers audio était indispensable pour garantir l'efficacité du traitement sonore. Cette phase d'homogénéisation consiste à garantir qu'il n'y ait pas de différences entre les données audio qui puissent perturber l'apprentissage et subséquemment l'évaluation des modèles. En effet, nous avons téléchargé des données qui provenaient de divers corpus et qui présentaient des caractéristiques sonores hétérogènes. Nous avons donc converti l'entièreté des fichiers d'enregistrement dans la même configuration standard. Ainsi, nous avons obtenu des données sous format WAV, en fréquence d'échantillonnage de 16 kHz et en piste mono. Le format WAV n'est pas compressé, ce qui signifie qu'il ne perd pas de données. Il a donc été choisi pour ses qualités de conservation intacte des traits acoustiques traités pour une tâche de reconnaissance de la parole. La fréquence de 16 kHz est nécessaire pour notre tâche, car elle permet une captation des fréquences de la voix humaine, tout en limitant la taille des volumes de données. Enfin, utiliser une piste mono, plutôt que stéréo, simplifie l'analyse du signal en supprimant les redondances dans les deux canaux. L'essentiel des informations audio à analyser sont déjà présentes dans une seule piste.

Dès que nous avons obtenu des enregistrements avec une configuration standardisée, la question de l'alignement et de la segmentation s'est posée. Après réflexion,

nous avons décidé de mettre en place cela en fichiers JSON, en se basant sur les mots. L'outil qui s'est imposé à nous est le **Montreal Forced Aligner** (MFA), capable d'aligner automatiquement de l'audio avec sa transcription textuelle, et qui permet également de dresser une segmentation pertinente basée sur des intervalles de durée définie, ou sur la détection de la parole ou des mots. Ce découpage automatique a donc l'avantage de ne pas être arbitraire. MFA est capable d'associer chacun des mots de la transcription, avec un horodatage précis. Nous avons ainsi constitué des segments d'une durée d'environ trente secondes, au mot près, et par la suite divisé ceux-ci par trois pour obtenir des segments de seulement dix secondes. Nous souhaitions obtenir deux tailles différentes afin de comparer les résultats entre les deux. Il était nécessaire de segmenter les fichiers et leurs transcriptions, car un audio trop long entraînerait une énorme baisse de résultats. Ce problème majeur chez les systèmes d'ASR est dû notamment à une accumulation d'erreurs au fil du temps, qui complexifie les calculs.

Enfin, nos méthodes de prétraitement sur les données auraient pu être vaines si nous n'avions pas effectué un équilibrage des données. Cette dernière opération consiste à sélectionner aléatoirement des données, de façon à faire tourner notre code sur des sous-ensembles de données qui étaient représentatifs du corpus dans sa globalité. En effet, les corpus sont structurés de telle manière qu'ils pourraient présenter des déséquilibres conséquents si nous traitions les fichiers dans l'ordre affiché. Par exemple, nous pourrions obtenir trop de données basées sur un même locuteur, ou contenant une surreprésentation de certains types de vocabulaire. Cela ajoute un biais significatif sur l'apprentissage du modèle. La randomisation des données est connue comme étant une pratique courante en science pour s'assurer de maintenir une répartition équitable entre les données connues et inconnues. De la même manière, cette étape est cruciale pour notre travail puisqu'elle donne la garantie que les résultats des évaluations sur les modèles peuvent être généralisés à l'entièreté du corpus. De plus, elles ne dépendent pas que d'un échantillon de données sur lequel un sur-apprentissage aurait été effectué.

4.3 Conception et mise en œuvre du pipeline

Le traitement de plusieurs modèles d'ASR sur des données audio provenant de nombreux fichiers peut être fastidieux. Puisque cette partie du travail était primordiale, il convenait de la diviser en plusieurs étapes. Nous avons donc considéré les problèmes un à un, et avons abouti par la suite à un pipeline entier qui permettait d'appliquer nos cinq modèles en même temps sur un même ensemble de données, de manière reproductible. Nous souhaitons également que les résultats obtenus soient exportés pour les rendre prêts pour l'évaluation. Nous expliquerons pas à pas comment nous sommes parvenus à produire cela.

Le premier problème que nous avons rencontré était que l'usage de ces modèles requiert de nombreuses installations, et qu'elles ne sont pas toutes compatibles entre elles. Certains demandent d'installer des modules qui ne sont pas disponibles dans Python 3.13, la version actuelle du langage. D'autres, tels que Canary à travers la plateforme NeMo, nécessitent d'utiliser d'anciennes versions de bibliothèques, ici pour Numpy. Par ailleurs, DeepSpeech nécessite l'installation de fichiers de pré-entraînement, puis a ensuite besoin de les appeler avant son exécution. La multiplication des besoins nous a poussé à créer des espaces d'installation isolés les uns des autres. Afin d'utiliser plusieurs environnements dans un même code, nous avons importé la bibliothèque *subprocess*. Celle-ci permet d'écrire du code dans une variable de chaîne de caractère, puis d'exécuter cette variable en appelant l'environnement déjà créé. L'utilisation de tous les modèles dans un seul code principal, aussi dit « *main* », nous donne l'occasion de créer des algorithmes efficaces, si seulement nous parvenons à éviter les conflits.

Après avoir installé correctement toutes les bibliothèques et *packages*, une nouvelle difficulté s'est posée à nous. Nous avons tout juste chargé les modèles pré-entraînés, notamment par HuggingFace et GitHub, et souhaitons que chacun d'entre eux puisse générer des transcriptions. Pour cela, nous avons tout d'abord converti tous nos fichiers audio en fichiers .wav, car c'est l'extension de base pour l'audio, et que tous les modèles peuvent lire ces données. Puis, pour tester le fonctionnement des transcriptions, nous avons tout d'abord essayé dans des fichiers *notebook* séparés. Lorsqu'un modèle fonctionnait, nous créons une fonction Python nommée « *run_* » suivi du nom du modèle, qui

permettait de l'exécuter sur un fichier wav. Nous stockions par la suite cela dans un fichier « .py » unique au modèle et en incluant les importations nécessaires pour ce modèle. Nous avons donc obtenu un dossier « fonctions » qui contenait chacun de ces fichiers python. Il ne suffisait plus que d'importer et d'appeler ces fichiers dans le *main* pour que le modèle demandé génère une transcription du fichier audio spécifié.

Savoir appliquer nos modèles sur un seul fichier audio ne suffit pas pour traiter un corpus entier. Nous avons donc créé une fonction « *modeles* » pour pallier ce problème. Celle-ci faisait appel aux codes Python pour chaque modèle, et itère cela sur tous les fichiers audio d'un corpus donné. Le but était d'obtenir en résultats un fichier JSON qui donne, modèle par modèle, les transcriptions des fichiers audio incluant une chaîne de caractères qui correspond au chemin du fichier. Obtenir cette notation JavaScript permettait de stocker puis de traiter l'entièreté des résultats pour un seul ensemble de données. Cette structure centralisée a été pensée pour une réutilisation de ces transcriptions lors de l'évaluation. Notre fonction d'application des modèles contenait également un calcul du temps d'exécution, pour chaque modèle. Ces données sont intéressantes pour une analyse ultérieure. Enfin, il faut préciser que nous avons utilisé les GPU de Google Colab pour résoudre le problème de vitesse de traitement, mais que Google pose une limite d'appels au Drive. Afin de régler ce problème, nous avons créé des samples de fichiers stockés de manière temporaire. Cela s'est fait grâce à la bibliothèque *datasets* de Hugging Face, qui crée un fichier JSONL, dans lequel chaque ligne contient un format JSON.

4.4 Protocole d'évaluation et axes d'analyse

Afin d'exploiter les données de transcription précédemment générées par les modèles d'ASR, nous avons créé un pipeline spécifique pour le traitement des métriques. Nous souhaitons obtenir des résultats chiffrés à partir de la comparaison entre la transcription initiale de référence et la transcription d'hypothèse générée. Pour cela, nous avons appliqué les cinq métriques sélectionnées aux fichiers d'entrée et de sortie. Puisque les données traitées étaient ici toutes exportées en format JSON, nous avons créé un nouveau *notebook* pour gérer les traitements liés aux métriques. Nous expliquerons ici

comment nous avons procédé pour effectuer cela, et mentionnerons quels axes d'analyse nous intéressaient dans la collecte de scores d'évaluation.

Tout d'abord, nous avons factorisé notre code en créant une fonction par métrique tel que nous l'avons fait pour les modèles. Ces fonctions sont sur mesure selon le critère d'évaluation, mais ont toutes les cinq en commun de prendre en entrée une référence et une hypothèse ; les deux sont définies dans le même type de structure de données. Elles utilisent le type de données adapté pour un usage de la fonction importée. Pour le WER, la fonction peut tourner directement après importation, et pour le SemanticWER, une lemmatisation est appliquée sur les données. En ce qui concerne, le score METEOR et le score BLEU, ils nécessitent une tokenisation ainsi qu'un lissage pour ce dernier. Enfin, le BERTScore fait appel à des listes et crée des scores de précision et de rappel. Afin d'utiliser ces fonctions, nous faisons appel à une clé de transcription dans le JSON généré par les modèles que nous mettons en parallèle avec le JSON de référence qui correspond en fonction du chemin spécifié. Ce code repose donc sur l'usage intelligent des structures de données de Python, notamment les listes et les dictionnaires.

Après avoir établi les fonctions individuelles par modèle, il était fortement pratique de créer une fonction qui applique toutes ces métriques en un algorithme. Cela favorise l'itération selon toutes les transcriptions générées et a la capacité d'être réutilisé sur d'autres corpus par la suite. L'intérêt d'une telle fonction est de mettre en place un point de centralisation des calculs en un lieu unique. Nous pouvions grâce à cela stocker les métriques de manière uniforme et efficace. Effectivement, les grands volumes de données transcrites nécessitaient un traitement accéléré qui réduisait le risque d'erreurs de manipulation. Pour finir, l'obtention de résultats doit nécessairement mener à diverses comparaisons entre les tests. Il convient d'exposer clairement quels étaient nos axes d'analyse avant de débiter l'exposition de nos résultats. Nous pouvons compter dans notre étude trois variations mono-factorielles. Ces altérations étaient des moyens de comparer les résultats obtenus. Nous avons donc étudié nos données selon les différents corpus de taille importante utilisés, selon des durées de segmentation distinctes, ou encore en contrastant les modèles directement sur des tests identiques. Cette démarche était une occasion de contraster les modèles sous des aspects multiples.

5. RÉSULTATS ET DISCUSSION

Maintenant que nous avons établi nos méthodes de travail et présenté nos objectifs de recherche, nous pouvons vous présenter nos résultats obtenus sur nos tests de génération de transcriptions. Ces données affichées mettent en évidence des tendances sur lesquelles il est pertinent de discuter.

5.1 Résultats des expériences

Pour chacun de nos tests, nous avons fait tourner chaque modèle sur cinq heures d'audio, afin d'obtenir un traitement réalisable tout en maintenant des résultats corrects et uniformes. Nos métriques sont exprimées en pourcentages, que ce soit pour les évaluations qualitatives, les distances de type erreur sur mot, ou pour comparer les temps relatifs d'exécution. Avant d'en arriver à notre bilan d'analyse, nous souhaitons prendre le temps d'exposer et de décrire les performances des modèles dans ce chapitre.

5.1.1 Résultats par modèle

Les versions exactes des modèles que nous avons utilisés, avec leurs dates d'apparition, sont les suivantes :

- DeepSpeech 0.9.3 - décembre 2020
- Wav2Vec2 LARGE - juin 2020
- Whisper Large-v3 - septembre 2022
- SeamlessM4T-Large-v2 - janvier 2025
- Canary-1B-Flash - mars 2025

Tableau 1: Comparaison des modèles de reconnaissance de la parole selon les métriques et le temps d'exécution par segment sans GPU

Métriques	DeepSpeech	Wav2Vec2	Whisper	SeamlessM4T	Canary
WER	38.1	28.1	23.4	72.4	20.0
SemanticWER	37.3	27.7	23.2	72.4	19.7
BLEU	53.0	66.6	76.4	13.6	79.0
METEOR	71.8	85.5	90.4	31.1	91.4
BERTScore	48.9	64.8	73.6	28.7	77.5
Score Moyen / Temps secondes	59.7 21.89	72.2 28.62	78.8 197.78	25.7 71.54	81.6 40.0

Dans ce premier tableau, nous comparons les modèles d'ASR appliqués sur 600 segments de trente secondes d'audio du corpus Supreme Court, et compare leurs temps d'exécution. Chaque colonne présente un modèle et contient ses divers résultats en pourcentage. Avons de débiter toute analyse de ces résultats, il convient de rappeler que les scores sont en pourcentages. De gauche à droite, nous présentons les modèles par ordre chronologique, et de haut en bas les métriques selon qu'elles mesurent un éloignement ou bien une similarité entre la référence et l'hypothèse. Le WER et le SemanticWER présentent un pourcentage inversé puisqu'ils correspondent à une distance, et nous remarquons que ces deux critères d'évaluation sont très fortement corrélés. Ils présentent effectivement une différence de point de moins de un pourcent pour chaque modèle analysé.

Les résultats du tableau montrent clairement que le modèle Canary est le performant, puisqu'il affiche les meilleurs résultats pour l'ensemble des métriques. Il atteint notamment le WER le plus faible (20,0%) tout en prouvant ses capacités de transmission du sens tel que le montre son BERTScore de 77,5%. En deuxième position, nous retrouvons Whisper qui atteint un score METEOR de 90.4 %, soit seulement un point derrière le modèle de tête. Puis, nous retrouvons Wav2Vec2 suivi de DeepSpeech avec respectivement un score moyen par métrique de 72.2 % et 59.7 %. En dernière place se situe SeamlessM4T, qui obtient des résultats très faibles. Ce système est optimisé pour de la génération de traductions, ce qui lui fait écrire des paraphrases. À l'exception de ce

dernier modèle, le classement est donc antéchronologique. Peut-être qu'un mauvais usage des données aurait pu baisser son score également. Pour finir, le temps d'exécution est à prendre en compte. Nous affichons cela pour 1 segment sans GPU, afin de donner un ordre d'idée des rapports de temps entre les modèles. Whisper est de loin le plus lent, avec environ 200 secondes par segment, car ses versions récentes ont grandement augmenté le nombre de paramètres, et le Large-v3 est le plus performant mais aussi le plus lent. Ces temps ne doivent cependant pas être pris trop au sérieux, puisqu'ils ne proviennent pas de tests avec processeurs virtuels puissants, par faute d'uniformisation des pipelines.

5.1.2 Résultats selon le corpus

Tableau 2: Comparaison des modèles de reconnaissance de la parole selon les corpus LibriSpeech et SupremeCourt

Corpus	Modèles	WER	SemanticWER	BLEU	METEOR	BERTScore
LibriSpeech	DeepSpeech	41.1	40.5	66.7	77.2	54.6
	Wav2Vec2	37.5	37.4	75.0	82.4	63.9
	Whisper	40.5	40.3	73.5	81.8	63.2
	SeamlessM4T	38.6	38.3	72.7	80.5	62.7
	Canary	36.1	35.9	76.0	82.1	65.5
Supreme Court	DeepSpeech	38.1	37.3	53.0	71.8	48.9
	Wav2Vec2	28.1	27.7	66.6	85.5	64.8
	Whisper	23.4	23.2	76.4	90.4	73.6
	SeamlessM4T	72.4	72.4	13.6	31.1	28.7
	Canary	20.0	19.7	79.0	91.4	77.5

Ce tableau compare les modèles d'ASR appliqués sur 600 segments de trente secondes d'audio sur nos deux corpus d'audio : LibriSpeech et Supreme Court. Chaque colonne présente une métrique différente, et les rangées sont divisées en deux grandes parties pour les corpus, afin de les comparer sur chacun des modèles. Nous allons donc ici accentuer notre lecture sur les différences majeures entre les deux ensembles de données.

Nous verrons ainsi les différences de performance selon qu’il s’agit de parole « lue » ou bruitée dans un contexte juridique.

La différence la plus notable lorsque nous introduisons LibriSpeech se trouve sur le modèle SeamlessM4T, qui atteint un WER de 38,6 %, contre 72,4 % pour Supreme Court. Sur ce premier corpus, il atteint des résultats environ 3 points derrière Canary, qui reste premier du classement, bien qu’il voie ses performances chuter, notamment en termes de taux d’erreurs sur mots qui viennent presque se doubler. Ce phénomène se produit similairement pour Whisper, qui n’atteint que 41,5 % de WER sur LibriSpeech contre 23,4 % sur son corpus de comparaison, et donc des scores presque égaux à ceux de SeamlessM4T. D’autre part, Wav2Vec2 atteint des scores presque aussi bons que Canary, et obtient même un score METEOR plus élevé, de 82,4 % contre 82,1 %. Bien que ce modèle ait initialement été développé en 2014, ses données d’entraînement proviennent notamment de LibriSpeech, ce qui explique sa robustesse lors de ces tests. Pour ce qui est de DeepSpeech, son WER est le plus mauvais de tous (41,1 %) pour les tests sur dix secondes, mais cela ne représente une chute que de trois points, et n’est pas très éloigné des scores pour les autres systèmes.

Par ailleurs, nous observons que LibriSpeech donne des taux d’erreur bien plus bas que Supreme Court, probablement car nous avons effectué une re-segmentation pour atteindre des audio de trente secondes, ou bien parce que des textes lus peuvent être assez complexes à retranscrire mot-à-mot. Les scores provenant de la traduction automatique sont en revanche parfois presque aussi élevés, comme par exemple le score BLEU de Canary qui ne descend que de 3 points, et obtient 76,0 % sur ces données. Cela nous fait comprendre que l’usage de ce corpus requiert probablement un type de segmentation différent, avec des segments plus courts. Il est donc délicat de comparer les résultats de deux ensembles de données entre eux. Nous remarquons également que ses scores sont plus rapprochés entre eux. Par exemple, le score BLEU se situe autour de 75 % pour toutes les métriques. Cette homogénéité s’explique par l’homogénéité du corpus.

5.1.3 Résultats selon la taille des segments

Tableau 3: Comparaison des modèles de reconnaissance de la parole selon les longueurs de segment de dix ou trente secondes

Corpus	Modèles	WER	SemanticWER	BLEU	METEOR	BERTScore
10 secondes	DeepSpeech	51.9	51.0	54.0	73.4	51.0
	Wav2Vec2	46.0	45.7	66.1	83.4	63.9
	Whisper	43.6	43.5	73.7	87.9	70.5
	SeamlessM4T	49.4	48.9	61.5	78.1	64.1
	Canary	40.3	39.7	75.2	88.7	70.8
30 secondes	DeepSpeech	38.1	37.3	53.0	71.8	48.9
	Wav2Vec2	28.1	27.7	66.6	85.5	64.8
	Whisper	23.4	23.2	76.4	90.4	73.6
	SeamlessM4T	72.4	72.4	13.6	31.1	28.7
	Canary	20.0	19.7	79.0	91.4	77.5

Cette figure compare les modèles d’ASR appliqués sur cinq heures d’audio du corpus Oyez. Nous mettons en contraste l’analyse de 1800 segments de dix secondes, et de 600 segments de trente secondes. Chaque colonne présente une métrique différente, et les rangées sont divisées en deux grandes parties pour chaque durée de segmentation alignée sur les mots. Pour cette raison-là, nous aurons tout d’abord l’occasion d’observer comment les métriques réagissent à ce changement de segmentation. Puis, nous allons mettre en avant les différences majeures liées à la variation de segmentation dans notre décryptage de ces données. Nous souhaitons tout particulièrement observer quels modèles sont plus résistants aux découpages audio fins, qui peuvent empêcher au système de bien saisir le contexte.

Tout d’abord, les deux évaluations de distance basées sur un taux d’erreurs connaissent une augmentation drastique lorsqu’elles sont testées sur des segments plus courts. Par exemple, ces scores sont doublés pour Canary et Whisper sur des tests de dix secondes comparé à trente, ce qui viendrait signifier une performance deux fois moins bonne. Ces métriques sont très sensibles à l’ajout ou à la suppression des mots, donc plus le segment est grand, plus elles risquent de donner un score bas. Nous remarquons en revanche que les trois métriques provenant du domaine de la traduction automatique connaissent une variations de score moindre, souvent seulement un ou deux points derrière sur des segments de dix secondes.

Pour ce qui est des modèles, DeepSpeech est le moins affecté par la diminution de durée des segments. Pour les tests sur segments de dix secondes, son WER ne monte que de 13,8 points, soit une augmentation relative de 36,2 %. Son score BLEU augmente de un point, en atteignant 54,0 %. Canary atteint toujours les scores les plus élevés, avec un WER de 40,3 %. À la suite de cela, Whisper atteint des scores environ deux ou trois points moins bons, de manière systématique. Juste derrière, Wav2Vec2 expose des scores proches des autres modèles pour les traitements sur dix secondes, avec un WER de 46,0 %. Ses valeurs BLEU, METEOR, et BERTScore sont presque identiques à celles pour des tests sur trente secondes, ce qui montre une certaine polyvalence. En quatrième position pour la métrique classique, nous retrouvons SeamlessM4T avec 49,4 %, soit une diminution de 23 points, ce qui lui rapproche de la perfection. En dernier, nous retrouvons DeepSpeech, qui malgré obtenir un WER correct de 51,9 %, admet un résultat BERTScore de 51,0 %, soit plus de dix points derrière tous les autres modèles sur cette métrique.

5.2 Discussion

Dans cette dernière partie, nous apporterons nos analyses personnelles en commençant par interpréter les résultats présentés précédemment. Nous chercherons à mettre clairement en avant, pour chaque modèle d’ASR étudié, ses forces et ses faiblesses majeures. Enfin, nous finirons par expliquer un peu plus en profondeur comment les métriques sont calculées au niveau du segment. Nous ferons pour cela appel à quelques exemples de phrases transcrites.

5.2.1 Interprétation des résultats des systèmes d'ASR

Nous allons interpréter les résultats afin d'expliquer les forces et faiblesses des cinq modèles d'ASR étudiés. Nous donnerons ici ce que nous pensons de chacun d'entre eux.

Tout d'abord, DeepSpeech figure généralement dans les scores les plus faibles. Cela est à nuancer puisque notre étude des segments de dix secondes nous montrent qu'il est presque capable de rivaliser les autres. Il connaît la meilleure vitesse d'exécution. Wav2Vec, en plus d'obtenir des scores corrects, est particulièrement puissant sur LibriSpeech. Ce modèle est polyvalent malgré sa légèreté. Nous pensons que sa structure simple est aussi une qualité, même si ce modèle n'est pas excellent dans des contextes bruités. Par la suite, Whisper figure toujours parmi les meilleurs scores. Nous pensons que son fonctionnement basé sur la multiplication des paramètres et des données d'entraînement lui offre une stabilité de performance, mais cela l'alourdi également. Puis, SeamlessM4T obtiens les résultats les plus douteux, notamment pour des segments de trente seconde pour Supreme Court. Nous pouvons estimer que c'est le modèle le moins adapté à cette tâche de génération de transcription, puisqu'il est davantage réglé pour la traduction automatique ou la génération multimodale. Pour finir, Canary est clairement le modèle le plus performant du lot, dans les diverses circonstances testées. Nous avons utilisé sa version Canary-1B-Flash, mais une Canary-1b-v2, supposément plus performante encore est apparue en août 2025.

5.2.2 Analyses des scores au niveau du segment

Nous allons ici étudier quelques phrases du corpus pour illustrer le comportement des différentes métriques. Nous affichons la segment de référence de dix secondes et sa transcription en Whisper, puis les scores calculés sur cet extrait.

Premier exemple :

Référence : *to see a change in that pattern so we ask that that this court we ask that this court affirm the ninth circuit thank you thank you counsel know*

Hypothèse : *to see a change in that pattern so we ask that this court affirm the ninth circuit thank you thank you counsel ms van aken you have three minutes remaining*

Scores : WER=48.3000, WER Sémantique=48.3000,
BLEU=71.9000, METEOR=73.8000, BERTScore=60.5000

Le WER et le WER sémantique donnent ici un résultat particulièrement mauvais, de 48,3 %. Ces distances sont élevées car ces outils sont très sensibles à l'insertion ou à la suppression de mots. La suppression des dédoublement de mots dans l'expression « *we ask that that* » ainsi que l'ajout de mots en fin de phrase dans l'hypothèse diminue significativement leur score. Nous remarquons par ailleurs dans l'ensemble de nos segments étudiés que ces deux métriques ont presque systématiquement des scores rapprochés de moins de trois points.

Deuxième exemple :

Référence : *of the rule that was specifically designed for yeah this which is rule b now he says b doesnt apply what that means*

Hypothèse : *of the rule that was specifically designed for this which is rule 54b now he says 54b doesnt apply*

Scores : WER=26.1000, WER Sémantique=25.0000, BLEU=48.5000,
METEOR=73.6000, BERTScore=66.8000

Le score BLEU est ici bien plus bas que tous les autres. L'explication la plus probable est que les modifications dans l'hypothèse influent sur les n-grammes, sans trop changer le sens. Par exemple, la suppression de « *yeah* » et le remplacement de « *rule b* » en « *rule 54b* », qui ne jouaient pas de rôle majeur au niveau sémantique, affectent pourtant grandement les séquences de mots.

Troisième exemple :

Référence : *i think i can by starting at ohio has no requirement that the electors vote for a to whom they are pledged you and your*

Hypothèse : *i think i can answer that by starting at the back ohio has no requirement that the electors vote for a person to whom they are pledged are you and your*

Scores : WER=24.0000, WER Sémantique=24.0000,
BLEU=56.1000, METEOR=96.6000, BERTScore=64.3000

Malgré des scores BLEU et BERTScore autour de 60 %, nous obtenons un METEOR de 96,6 %. Cette évaluation presque parfaite de la part de cette métrique vient montrer qu'elle ne pénalise que très peu l'ajout de mots dans l'hypothèse. Effectivement, nous retrouvons entre autres les mots « *answer that* » qui n'étaient pas présents dans la référence. À l'inverse, aucun mot de la référence n'a disparu de l'hypothèse. Cela aurait empêché METEOR de trouver des synonymes, ce qui aurait diminué son score.

Quatrième exemple :

Référence : *had the pen along the way the veto power is what is most important and we think its especially easy to get there in the context of an entity like amtrak which is*

Hypothèse : *had the pen along the way the veto power is what is most important and we think its especially easy to get there in a context of an entity like amtrak which is*

Scores : WER=3.0000, WER Sémantique=3.0000,

BLEU=91.8000, METEOR=96.2000, BERTScore=99.0000

BERTScore obtient ici le meilleur résultat comparé aux autres métriques, en ne pénalisant la différence textuelle que de 1 %. Nous pouvons observer que dans cet exemple, la seule différence entre les deux transcriptions se situe sur la variation d'un article. En effet, la référence contient « the context », tandis que l'hypothèse écrit « a context ». Ce changement est lexical, et n'a donc pas d'effet important sur la sémantique, or BERTScore évalue la similarité contextuelle.

6. CONCLUSION

6.1 Synthèse des résultats

Les expérimentations menées ont permis d'évaluer cinq modèles de reconnaissance automatique de la parole selon cinq métriques d'analyse. Nous avons exploré l'influence que peut avoir le changement de corpus ou de taille de segmentation. Le modèle Canary, sous sa version Canary-1B-Flash, a été le modèle le plus performant dans l'ensemble des tests. Il a notamment obtenu un WER de 20,0 % sur cinq heures d'audio segmentées en trente secondes pour le corpus Supreme Court. À l'inverse, SeamlessM4T-Large-v2 a présenté certaines lacunes. Lors du même test, ce modèle optimisé pour la traduction et la génération de phrase a obtenu un WER de 72,4 %. Nous pouvons donc questionner les performances de ce modèle ou bien la qualité de nos alignements. Par ailleurs une corrélation extrêmement forte a été observée entre le WER et le SemanticWER. Enfin, nous examiné les métriques dans des segments isolés pour confirmer leurs spécificités.

La comparaison des performances entre les corpus LibriSpeech et Supreme Court a mis en lumière des comportements variés des modèles. SeamlessM4T, par exemple, a obtenu de bien meilleures performances sur LibriSpeech, notamment sur le taux d'erreur sur mots, tandis que les autres modèles ont connu une chute drastique de ce score. Wav2Vec2 a également obtenu de bons scores sur ce dataset, ce qui s'explique par le fait qu'il ait été pré-entraîné sur LibriSpeech en partie. Bien que LibriSpeech ait généralement produit des taux d'erreur WER plus faibles, les métriques issues de la traduction automatique ont affiché une plus grande stabilité entre les deux corpus.

Nous avons également analysé l'impact de la taille des segments audio de dix contre trente secondes. Cela a montré que les métriques de taux d'erreurs sont très sensibles à la réduction de la durée des segments, leurs scores pouvant doubler si on réduit la taille du segment. La variation de score pour les autres métriques est moindre. DeepSpeech a connu la plus petite réduction de robustesse lorsque nous nous testions des segments de dix secondes plutôt que trente secondes.

6.2 Limites de l'étude

Notre étude comporte cependant certaines zones d'ombres et des biais liés à nos contraintes de travail. Reconnaître les limites de méthode et d'application de nos tâches nous permettra de nuancer nos résultats. Nous allons donc lister ici les éléments qui nous semblent restreindre le cadre de notre analyse.

Tout d'abord, nos données ne peuvent pas être exhaustives. Même si nos divers corpus offrent une certaine diversité en termes de genre discursif, certains points ne sont pris en compte par aucun d'entre eux. Par exemple, la langue présentée dans l'ensemble de nos données est un anglais standard américain, particulièrement pour Oyez et LibriSpeech. Nous avons initialement pensé à utiliser le corpus Chime6, qui contient des enregistrements de conversations téléphoniques dans des contextes variés. Bien que Chime6 puisse contenir des très légères variations dialectales, nous ne retrouvons ni *code-switching*, ni de discussions en espaces publics dans les communications étudiées. L'absence de tels éléments rend la généralisation des résultats plus délicate. Les corpus utilisés couvrent effectivement des contextes trop peu variés linguistiquement, avec une prévalence des données à contexte contrôlé, strictement en anglais. De plus, il est très probable que les annotations manuelles contiennent déjà des erreurs, auquel cas les performances des moteurs peuvent être mal estimées. Les annotateurs sont certes qualifiés, mais leurs transcriptions sont le fruit d'un travail humain qui par définition est perfectible. Ce travail peut inclure une petite part de subjectivité qui influence l'évaluation. Une partie des erreurs reconnues peut en réalité provenir d'incohérences dans les annotations, tel qu'un usage non adapté des ponctuations. Enfin, nos sous-ensembles de données sont de taille modeste pour faciliter un traitement avec des processeurs de performance moyenne. La fiabilité de nos statistiques peut être remise en compte. En effet, nous pouvons supposer que les particularités de nos petits corpus ont pour beaucoup conditionné nos résultats.

Ensuite, notre utilisation des modèles peut être discutée. Le mémoire ne se contente d'analyser que cinq modèles alors qu'un projet plus long aurait pu en inclure de nombreux autres. Naturellement, cette contrainte implique que certains types d'architecture ne sont pas représentés. Par exemple, aucun ne contient de structure HMM-DNN, qui est un système hybride classique incluant modèle de Markov et réseau de neurone. De même, il

existe des modèles entraînés spécifiquement sur de la parole chevauchée ou sur des segments longs. Nos expérimentations n’ont permis de tester que la transcription textuelle de données audio. D’autres tâches telles que la génération d’audio et la traduction automatique sont pourtant à la portée de certaines structures multimodales, tel que SeamlessM4T. La gestion de locuteurs, ou « *speaker diarization* », permise par Whisper est également une autre piste à étudier. Estimer la robustesse des infrastructures en ne se penchant que sur une tâche peut poser problème. De plus, en raison d’exigences computationnelles, nous n’avons pas effectué de *fine-tuning*, c’est-à-dire de ré-entraînement des dispositifs pour prendre parti de tous leurs paramètres d’optimisation. Plus largement, les restrictions sur les GPU virtuels nous ont poussé à nous concentrer sur un nombre restreint d’éléments. Un dernier point à relever est que l’évolution rapide des dispositifs de reconnaissance de la parole fait que nos analyses ne s’appliquent qu’à l’instant présent, et que la validité de nos résultats sera à remettre en question. En outre, la fiabilité et l’utilité exacte de nos métriques méritent d’être interrogées. À l’exception du WER et de Semantic WER, les critères d’évaluation que nous avons utilisés provenaient du domaine de la traduction automatique, ce qui signifie qu’ils ont été entraînés à reconnaître des structures de langue complexes. Cela veut dire en revanche qu’ils ne sont donc pas parfaitement adaptés à juger les transcriptions d’audio. Ainsi, la bonne ou mauvaise gestion des silences et des intonations n’est pas prise en compte, et les erreurs liées à la segmentation ou aux confusions phonétiques ne sont pas perçues. En plus de cela, chaque métrique représente un aspect différent. Interpréter les résultats est une tâche complexe lorsque nous ne possédons pas d’interprétation unique. Le score BLEU évalue une similarité en n-grammes, alors que le WER exprime un taux d’erreurs sur mots, et que BERTScore utilise des plongements lexicaux. De plus, les métriques ne sont pas totalement corrélées aux évaluations humaines. Enfin, nos choix méthodologiques concernant notamment la segmentation, le prétraitement ou la manière d’importer les modèles, ont pu orienter les résultats obtenus, ce qui ajoute un biais supplémentaire. De façon équivalente, nos axes de comparaison étaient assez restreints, puisqu’ils se concentraient seulement sur la différence de corpus et de durée de segmentation. Nous aurions par ailleurs pu étudier diverses méthodes pour cette dernière tâche, autres que le MFA.

6.3 Perspectives

Si nous prenons en compte les limites précédemment identifiées, nous pouvons dresser plusieurs pistes d’approfondissement pour des potentiels travaux ultérieurs. Poursuivre cette étude serait nécessaire afin d’affiner l’évaluation des systèmes de reconnaissance automatique de la parole. Cela apporterait de la nuance vis-à-vis de nos résultats et orienterait la recherche vers des applications plus concrètes.

Premièrement, il serait pertinent de se mettre à l’utilisation de données plus élargies et affinées. L’ajout de corpus rendrait le travail plus complet. Un premier exemple est le corpus MSR-86K qui contient des dizaines de milliers d’heures d’audio, transcrites en quinze langues. Celui-ci utilise des données multilingues provenant de vidéos YouTube et il est continuellement mis à jour grâce aux transcriptions automatiques du réseau social. De manière analogue, le Corpus d’Étude pour le Français Contemporain (CEFC), qui compte environ 4 millions de mots, contient des enregistrements audio de diverses régions francophones. Ces données incluent des variantes dialectales et des contextes de communication variés dans des milieux publics. Le but d’un élargissement des ressources est de pouvoir tester les mécanismes de génération de transcription sur des utilisations réelles. Ainsi, confronter les systèmes à certains défis spécifiques tels que le chevauchement de parole, les bruitages ou la variation linguistique prononcée. En outre, un autre aspect à améliorer dans nos ressources est celui du renforcement des transcriptions. Certaines méthodes comme la double annotation puis la validation croisée permettent d’enrichir un corpus. De ce fait, nous pourrions ajouter des informations phonétiques ou grammaticales à nos transcriptions. Il existe des outils semi-automatiques qui permettent d’accomplir cela assez simplement, tel que MAUS pour l’alignement phonétique.

Secondement, une ouverture vers d’autres modèles et métriques nous semble faire sens. La grande quantité d’outils développés dans le domaine du *speech-to-text*, ne serait-ce que pendant les quelques dernières années, a créé une immense richesse technologique. Une étude ultérieure pourrait ajouter des modèles à comparer avec ceux déjà utilisés. Par exemple, les modèles hybrides HMM-DNN du framework Kaldi se distinguent pour leurs qualités dans le milieu de la reconnaissance vocale. Il serait intéressant de voir si cette architecture moderne est réellement plus performante que celles classiques et légères. De

même, le modèle Moshi, développé par le laboratoire Kyutai, offre une approche avec délai pour traiter les différents locuteurs dans un audio. Sur le sujet des métriques, de nombreuses méthodes existent pour obtenir un jugement plus objectif. Par exemple, d'autres variantes au taux d'erreur sur mots peuvent être mentionnées. Le *Normalized Error Rate* (NER) ajuste l'impact des erreurs selon une pondération sur la compréhension du message, et le *Character Error Rate* (CER) calcule les erreurs sur les caractères, ce qui est nécessaire pour des langues non flexionnelles comme le chinois. Une autre pratique en termes d'évaluation consisterait à combiner toutes les métriques puis de s'aider des calculs de précision et de rappel pour créer un score unique. Enfin, les expérimentations futures pourraient contenir un travail d'affinage sur les paramètres des modèles en fonction de la tâche effectuée.

En conclusion, nous devons maintenir à l'esprit que ce travail doit répondre à des usages concrets et prendre en compte les évolutions à vitesse fulgurante du domaine d'étude. Lors de nos analyses, nous nous sommes concentrés sur la transcription textuelle. Cependant, les systèmes modernes semblent exiger des analyses impliquant également de la traduction automatique, de la *diarisation* ou encore de la génération d'audio. Nous pouvons parler d'une interopérabilité de plus en plus présente entre ces tâches. Cette mutualisation des connaissances a pour objectifs d'aboutir à des applications pratiques comme le sous-titrage instantané ou l'analyse vocale contextuelle. Pour cela, les futures études pourraient s'intéresser à appliquer les modèles dans des situations plus concrètes, ce qui nécessiterait en préalable la création d'un corpus adapté à cette recherche. Alternativement, la mise en place de tests expérimentaux en conditions réelles serait une manière intéressante de valider la pertinence de ces systèmes. Enfin, nous avons réfléchi à la rapide évolution du domaine. Nous proposons de régulariser l'utilisation de suivis au fil du temps pour dresser des tendances dans la progression des moteurs de reconnaissance de la parole. Il serait certainement souhaitable que la communauté scientifique du TAL et de l'ASR mette en place un classement collaboratif commun des modèles, de manière officielle, transparente et permanente. Ce système serait effectué selon des études reconnues et mis à jour régulièrement, et chercherait à harmoniser les méthodes d'évaluation.

BIBLIOGRAPHIE

- [1] Conneau, A., Baevski, A., Collobert, R., Mohamed, A., & Auli, M. (2021).
Unsupervised cross-lingual representation learning for speech recognition.
In *Interspeech 2021*. arXiv:2006.13979. <https://doi.org/10.48550/arXiv.2006.13979>

- [2] DeepSpeech. (2014).
DeepSpeech: Scaling up end-to-end speech recognition.
<https://arxiv.org/abs/1412.5567>

- [3] DeepSpeech. (n.d.).
DeepSpeech repository.
<https://github.com/mozilla/DeepSpeech>

- [4] Facebook AI Research. (2020).
Wav2Vec 2.0: A framework for self-supervised learning of speech representations.
<https://arxiv.org/abs/2006.11477>

- [5] Facebook AI Research. (n.d.).
wav2vec 2.0 repository.
<https://github.com/facebookresearch/fairseq/tree/main/examples/wav2vec>

- [6] Facebook AI Research. (2025).
SeamlessM4T repository.
https://github.com/facebookresearch/seamless_communication

- [7] Gladia.io. (2023, décembre).
A review of the best ASR engines and the models powering them in 2024.
www.gladia.io/blog/a-review-of-the-best-asr-engines-and-the-models-powering-them-in-2024

- [8] Guo, W., Zhang, C., Song, X., Chen, Z., & Liu, Q. (2022).
H_eval: A hybrid evaluation metric for automatic speech recognition.
In **EMNLP 2022**. arXiv:2211.01722. <https://doi.org/10.48550/arXiv.2211.01722>
- [9] Han, W., Xu, Q., Haghani, P., Chen, J., & Prabhavalkar, R. (2023).
Chirp: Large-scale multilingual speech recognition with 2 billion parameters.
arXiv preprint arXiv:2304.03728. <https://doi.org/10.48550/arXiv.2304.03728>
- [10] Huang, K., Wang, Z., Xu, H., & Chen, Y. (2024).
SeMaScore: Semantic and error-aware evaluation for ASR outputs.
arXiv preprint arXiv:2401.07506. <https://doi.org/10.48550/arXiv.2401.07506>
- [11] Kheddar, H., Hemis, M., & Himeur, Y. (2024).
Automatic Speech Recognition using Advanced Deep Learning Approaches: A survey.
arXiv preprint arXiv:2403.01255. <https://arxiv.org/abs/2403.01255>
- [12] Lavie, A., & Agarwal, A. (2005).
METEOR: An automatic metric for machine translation evaluation.
<https://aclanthology.org/W05-0909.pdf>
- [13] Levenshtein, V. I. (1966).
Binary codes capable of correcting deletions, insertions and reversals.
<https://nymity.ch/sybilhunting/pdf/Levenshtein1966a.pdf>
- [14] NVIDIA. (2024).
Canary: Efficient multilingual speech recognition at scale.
<https://arxiv.org/abs/2406.19674>
- [15] NVIDIA. (2025).
Canary model repository.
<https://huggingface.co/nvidia/canary-1b-v2>

- [16] OpenAI. (2022).
Whisper: Robust speech recognition and translation.
<https://arxiv.org/abs/2212.04356>
- [17] OpenAI. (n.d.).
Whisper repository.
<https://github.com/openai/whisper>
- [18] Panayotov, V., Chen, G., Povey, D., & Khudanpur, S. (2015).
LibriSpeech: an ASR corpus based on public domain audio books. ICASSP 2015.
Consulté sur le site de Daniel Povey : <https://www.danielpovey.com/publications.html>
- [19] Panayotov, V., Chen, G., Povey, D., & Khudanpur, S. (2015). *LibriSpeech: An ASR corpus based on public domain audiobooks*. Open Speech and Language Resources,
<https://www.openslr.org/12>
- [20] Papineni, K., Roukos, S., Ward, T., & Zhu, W. (2002).
BLEU: A method for automatic evaluation of machine translation.
<https://aclanthology.org/P02-1040.pdf>
- [21] Seamless Communication, Barrault, L., Chung, Y.-A., Meglioli, M. C., et al. (2023).
Massively Multilingual & Multimodal Machine Translation.
<https://arxiv.org/abs/2308.11596>
- [22] Speech Recognition and its Applications in 2025. (2025, janvier).
OpenCV Blog.
<https://opencv.org/blog/applications-of-speech-recognition/>
- [23] Top 11 Voice Recognition Applications & Examples in 2025. (2025, juin).
AIMultiple.

<https://research.aimultiple.com/voice-recognition-applications/>

- [24] Tumminia, J., Kuznecov, A., Tsilerides, S., Weinstein, I., McFee, B., Picheny, M., & Kaufman, A. R. (2021).
Diarization of Legal Proceedings: Identifying and Transcribing Judicial Speech from Recorded Court Audio. In *Proceedings of the 22nd Annual Conference of the International Speech Communication Association (INTERSPEECH 2021)*.
<https://arxiv.org/pdf/2104.01304v1.pdf>
- [25] U.S. Supreme Court. (n.d.).
Supreme Court cases.
Oyez. <https://www.oyez.org/cases>
- [26] Xu, Q., Likhomanenko, T., Kahn, J., Hannun, A., Synnaeve, G., & Collobert, R. (2020).
ASAPP-ASR: Multistream CNN and self-attentive SRU for speech recognition.
In **Interspeech 2020**. arXiv:2005.10469. <https://doi.org/10.48550/arXiv.2005.10469>
- [27] Ye, M., Li, J., & Gong, Y. (2023).
NoRefER: Reference-less evaluation for ASR systems.
arXiv preprint arXiv:2306.12577. <https://doi.org/10.48550/arXiv.2306.12577>
- [28] Zhang, D., Logan, B., & Glass, J. (2021).
Semantic Word Error Rate for evaluation of semantic error patterns in speech recognition.
<https://arxiv.org/abs/2106.02016>
- [29] Zhang, T., Kishore, V., Wu, F., Weinberger, K., & Artzi, Y. (2019).
BERTScore: Evaluating text generation with BERT.
<https://arxiv.org/abs/1904.09675>
- [30] Zhang, Y., Li, H., & Zhao, T. (2025).

ASR-FAIRBENCH: A fairness-aware evaluation framework for speech recognition.

arXiv preprint arXiv:2505.11572. <https://doi.org/10.48550/arXiv.2505.11572>